สรุปผลการประเมินระบบ

Agentic AI ด้านการเงินส่วนบุคคลสำหรับผู้ใช้ชาวไทย

Pakkaphon (รหัสนักศึกษา 66070146) คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

สรุปผลใน 1 หน้า

ระบบเป็นสถาปัตยกรรมแบบหลาย Agent (Multi-Agent Architecture) ที่มี Router Agent จำแนกเจตนาของคำถาม แล้วส่งต่อให้ Agent เฉพาะทาง 6 ตัว หรือ General Chat ระบบที่ใช้งานจริงใช้ Google Gemini 3.5 Flash คณะผู้จัดทำประเมินระบบ 4 ด้าน ผลโดยสรุปเป็นดังตาราง

การทดสอบ	คำถามที่ต้องการตอบ	ผลลัพธ์
สถาปัตยกรรม	แบบใดทำงานสำเร็จมากที่สุด	บน DeepSeek แบบ Agent เดียวสำเร็จ 98.9% สูงกว่าแบบศูนย์กลาง 87.2% ที่ใช้ในระบบ ความต่างทั้งหมดมาจากคำถามข้ามหัวข้อ แต่แบบศูนย์กลางใช้ token น้อยกว่า 3.6 เท่า
การแยกหลายเจตนา	แก้จุดอ่อนคำถามข้ามหัวข้อได้หรือไม่	คำถามข้ามหัวข้อสำเร็จเพิ่มจาก 61.1% เป็นประมาณ 86.1% ($p = 0.012$) โดยความแม่นยำของคำถามหัวข้อเดียวไม่ลดลงอย่างมีนัยสำคัญ
ระดับการคิดของ Router	ใช้ระดับต่ำสุดแล้วยังแม่นยำหรือไม่	แม่นยำเท่าเดิม (95.9% เทียบกับ 96.2%) และเร็วขึ้นเกือบเท่าตัว (1.36 เทียบกับ 2.59 วินาที)
การค้นคืนเอกสาร	โมเดลเวกเตอร์แทนความหมายตัวใดดีที่สุด	Gemini ค้นคืนได้ดีที่สุด (nDCG@10 0.805) แต่คำตอบสุดท้ายของ 3 โมเดลที่ดีที่สุดถูกต้องใกล้เคียงกัน (92.5–94.2%)
การคำนวณภาษี	ภาษีถูกต้องตามกฎปี 2569 หรือไม่	ถูกต้อง 26 จาก 26 กรณี ถ้าไม่ใช้เครื่องมือคำนวณ โมเดลตอบถูก 7 จาก 8 กรณี และยังใช้เพดานประกันสังคมแบบเก่า

ข้อสรุปหลัก แบบศูนย์กลางที่เพิ่มการแยกหลายเจตนาแล้ว ปิดช่องว่างกับแบบ Agent เดียวได้เกือบหมด โดยยังประหยัด token สำหรับคำถามหัวข้อเดียว ส่วนการตั้งค่า Router การเลือกโมเดลเวกเตอร์ และการคำนวณภาษี ผลการทดลองรองรับการออกแบบที่ใช้อยู่ทั้งหมด

ตัวเลขทุกตัวในรายงานนี้มาจากไฟล์ผลการทดลองโดยตรง และทุกรอบที่ล้มเหลวในการทดสอบสถาปัตยกรรมได้อ่านตรวจด้วยมือก่อนนับผล ข้อมูลรายข้อทั้งหมดอยู่ในรายงานฉบับเต็มภาษาอังกฤษ (evaluation-report.pdf)

1 วิธีทดสอบโดยย่อ

ระบบสร้างโมเดลภาษาผ่านส่วนสร้างโมเดลกลางที่รองรับ Google Gemini, Ollama และ OpenRouter จึงเปลี่ยนโมเดลได้ด้วยการตั้งค่าเพียงจุดเดียว การทดสอบสถาปัตยกรรมใช้โมเดล 2 ตระกูล คือ gpt-oss:20b และ DeepSeek V4.1 Flash ส่วนการทดสอบอื่นใช้ Gemini ตัวเดียวกับระบบจริง

ชุดข้อมูล	จำนวน	รายละเอียด
งานทดสอบสถาปัตยกรรม	60	หัวข้อเดียว 40 งาน ข้ามหัวข้อ 12 งาน และคำถามกว้างที่ต้องถามกลับ 8 งาน
คำถามจำแนกเจตนา	185	เขียนใหม่ 150 ข้อ และชุดเดือนกันยายน 35 ข้อ
คำถามหลายหัวข้อ	30	หลายหัวข้อ 22 ข้อ (2–5 หัวข้อ) และคำถามเดียวที่ฟังคล้ายหลายหัวข้อ 8 ข้อ
คำถามค้นคืนเอกสาร	120	ใช้ภาษาแบบผู้ใช้ พร้อมไฟล์และคำสำคัญที่ใช้ตัดสินว่าเอกสารเกี่ยวข้อง
กรณีภาษี	26	กรณีเดิม 20 กรณี และกรณีตามกฎปี 2569 อีก 6 กรณี

การเปรียบเทียบใช้ช่วงความเชื่อมั่น 95% แบบ Wilson และใช้การทดสอบ McNemar แบบแม่นตรงเมื่อเทียบงานเดียวกันในรอบเดียวกัน ค่า pass^3 คือสัดส่วนงานที่สำเร็จครบทั้ง 3 รอบ ซึ่งใช้วัดความสม่ำเสมอ

2 การเปรียบเทียบสถาปัตยกรรม

คณะผู้จัดทำสร้างสถาปัตยกรรม 4 แบบจาก Agent และเครื่องมือชุดเดียวกัน ได้แก่ แบบ Agent เดียวที่มีเครื่องมือทั้ง 27 รายการ แบบศูนย์กลาง (Hub-and-Spoke) ที่ใช้ในระบบจริง แบบลำดับชั้น (Hierarchical) และแบบส่งต่อระหว่าง Agent (Peer-to-Peer) ทุกแบบทำงาน 60 งาน งานละ 3 รอบ งานหนึ่งนับว่าสำเร็จเมื่อส่งถูก Agent เรียกเครื่องมือที่จำเป็นครบ ตอบตัวเลขถูก และบันทึกข้อมูลถูกต้อง

สถาปัตยกรรม (DeepSeek)	สำเร็จรวม	ข้ามหัวข้อ	pass^3	Token ขาเข้า	เวลา (วินาที)
Agent เดียว	98.9%	100.0%	96.7%	42,555	3.6
แบบส่งต่อระหว่าง Agent	91.7%	66.7%	88.3%	14,807	5.6
แบบศูนย์กลาง (ระบบจริง)	87.2%	61.1%	83.3%	11,649	4.4
แบบลำดับชั้น	85.0%	55.6%	80.0%	12,280	5.3

บน gpt-oss:20b ผลต่างออกไป แบบ Agent เดียวและแบบศูนย์กลางเสมอกัน (83.9% และ 83.3%, $p = 1.0$) และแบบศูนย์กลางสม่ำเสมอที่สุด (pass^3 78.3% เทียบกับ 73.3%)

ข้อสรุป กับโมเดลที่เก่ง แบบ Agent เดียวชนะเพราะใช้เครื่องมือข้ามด้านได้ในคำถามเดียว ส่วนแบบศูนย์กลางส่งคำถามให้ Agent ตัวเดียว จึงตอบคำถามข้ามหัวข้อไม่ครบ ข้อดีของแบบศูนย์กลางคือใช้ token น้อยกว่า 3.6 เท่า และไม่เสียเปรียบเมื่อใช้โมเดลที่อ่อนกว่า

3 การแยกหลายเจตนา

จากจุดอ่อนข้างต้น คณะผู้จัดทำเพิ่มการแยกหลายเจตนา (Multi-intent Routing) ให้ Router Agent แยกข้อความที่ถามหลายเรื่องเป็นงานย่อย งานละ 1 Agent ตามลำดับที่ผู้ใช้ถาม โดยไม่จำกัดจำนวนงาน Agent ทำงานทีละตัว ตัวหลังเห็นคำตอบของตัวก่อนหน้า แล้วระบบรวมคำตอบเป็นข้อความเดียว คำถามหัวข้อเดียวยังทำงานแบบเดิมทุกประการ

เนื่องจากแก้เฉพาะ Router Agent คณะผู้จัดทำจึงทดสอบเฉพาะส่วนที่เปลี่ยน 3 ส่วน

การทดสอบ	ผลลัพธ์
คำถามหัวข้อเดียว 185 ข้อ	94.6% เทียบกับ 95.7% ก่อนแก้ ต่างกันอย่างไม่มีนัยสำคัญ ($p = 0.69$) และแยกผิดเพียง 1 ข้อ
คำถามหลายหัวข้อ 30 ข้อ	แยกถูกทุก Agent และถูกลำดับ 22 จาก 22 ข้อ รวมข้อความ 3–5 หัวข้อ และไม่แยกคำถามเดียวผิดเลย (8 จาก 8 ข้อ)
ทำงานจริงบน DeepSeek	รันซ้ำ 6 งานข้ามหัวข้อที่แบบศูนย์กลางเคยล้มเหลว (18 รอบ) แล้วรวมกับผลเดิม

สถาปัตยกรรม (DeepSeek)	สำเร็จรวม	ข้ามหัวข้อ	ข้ามหัวข้อ pass^3
แบบศูนย์กลาง (เดิม)	87.2%	61.1%	6/12
แบบศูนย์กลาง + แยกหลายเจตนา (ประมาณการ)	92.2%	86.1%	10/12
Agent เดียว	98.9%	100.0%	12/12

ใน 18 คู่ที่รันซ้ำ แบบใหม่สำเร็จในจุดที่แบบเดิมล้มเหลว 10 ครั้ง และกลับกันเพียง 1 ครั้ง ($p = 0.012$) ข้อแลกเปลี่ยนคือคำถามหลายหัวข้อใช้ทรัพยากรมากขึ้น โดยเรียกโมเดลเพิ่มจาก 3.4 เป็น 5.8 ครั้ง token จาก 11.2k เป็น 24.1k และเวลาจาก 9.0 เป็น 13.0 วินาที ส่วนคำถามหัวข้อเดียวไม่ได้รับผลกระทบ

ข้อควรระวัง ตัวเลข 86.1% เป็นค่าประมาณ เพราะไม่ได้รันซ้ำ 6 งานข้ามหัวข้อที่ไม่เคยล้มเหลว ความล้มเหลวที่เหลือ 5 รอบอ่านตรวจด้วยมือแล้ว คือส่งคำถามเรื่องการออมไปผิด Agent 2 รอบ และ Agent ภาษีของ DeepSeek ตอบว่าง 3 รอบ ข้อหลังทำให้พบข้อบกพร่องที่แสดงหัวข้อว่างเปล่า ซึ่งแก้ไขแล้ว

4 ระดับการคิดของ Router Agent

บทที่ 3 ระบุว่า Router Agent ใช้ระดับการคิดต่ำสุดของ Gemini โดยไม่เสียความแม่นยำ การทดสอบนี้ใช้คำถาม 185 ข้อ ข้อละ 2 รอบ ผลการทดสอบเบื้องต้นพบว่าระดับ low และ minimal ใช้ token สำหรับการคิดเป็นศูนย์เท่ากัน จึงเทียบ minimal กับค่าเริ่มต้นของโมเดล

โมเดล	ระดับการคิด	ความแม่นยำ	เวลากลาง (วินาที)	Token การคิด
gemini-3.5-flash	minimal (ระบบจริง)	95.9%	1.36	0
gemini-3.5-flash	ไม่ตั้งค่า	96.2%	2.59	272
gemini-3.5-flash-lite	minimal	93.8%	0.88	0
gemini-3.5-flash-lite	high	96.5%	1.93	469

ข้อสรุป ระดับ minimal ผ่านเกณฑ์ไม่ด้อยกว่า ความแม่นยำต่างกัน -0.3 จุด ช่วงความเชื่อมั่นอยู่ที่ -2.2 ถึง $+1.6$ จุด ซึ่งอยู่เหนือเกณฑ์ -3 จุดทั้งช่วง และเร็วขึ้นประมาณ 1.26 วินาที รองรับข้อความในบทที่ 3 ส่วน Flash-Lite แม่นยำน้อยกว่า 2.2 จุด จึงไม่นำมาใช้ หลังจากนั้นมีการปรับคำสั่งของ Router อีก 2 ครั้ง ความแม่นยำอยู่ที่ 95.7% และ 94.6% ซึ่งไม่ต่างจากเดิมอย่างมีนัยสำคัญ

5 การค้นคืนเอกสาร

คณะผู้จัดทำเทียบวิธีค้นคืน 5 แบบ ด้วยคำถาม 120 ข้อ บนฐานความรู้ที่ตัดข้อความแบบเดียวกับระบบจริง จากนั้นให้ Gemini ตอบคำถามจากเอกสาร 3 ชิ้นแรกของแต่ละวิธี และให้ DeepSeek ซึ่งเป็นโมเดลต่างตระกูลเป็นผู้ตัดสิน ผู้ตัดสินให้ผลตรงกับการอ่านตรวจด้วยมือ 28 จาก 30 คำตอบ

วิธีค้นคืน	nDCG@10	Recall@3	คำตอบถูกต้อง	ตรงกับแหล่งอ้างอิง
gemini-embedding-001 (ระบบจริง)	0.805	0.900	93.3%	88.3%
BAAI/bge-m3	0.724	0.842	94.2%	82.5%
multilingual-e5-large-instruct	0.722	0.825	92.5%	86.7%
BM25	0.568	0.683	—	—
MiniLM (ตัวสำรองเดิม)	0.394	0.433	—	—

ข้อสรุป Gemini ค้นคืนได้ดีกว่าทุกวิธีอย่างมีนัยสำคัญ จึงใช้ต่อในระบบจริง ส่วน MiniLM ไม่เหมาะกับภาษาไทย คณะผู้จัดทำจึงเปลี่ยนตัวสำรองบนเครื่องเป็น bge-m3 อย่างไรก็ตาม ความถูกต้องของคำตอบสุดท้ายของ 3 วิธีแรกไม่ต่างกันอย่างมีนัยสำคัญ เพราะโมเดลมักตอบถูกได้แม้เอกสาร 3 ชิ้นจะเกี่ยวข้องเพียงบางส่วน

6 การคำนวณภาษี

ตัวคำนวณภาษีและคำสั่งของ Tax Agent ได้รับการแก้ไขตามกฎปี 2569 เมื่อวันที่ 3 พฤศจิกายน 2569 คณะผู้จัดทำจึงทดสอบใหม่ทั้งหมด และเพิ่ม 6 กรณีที่ถ้าใช้กฎเก่าจะได้คำตอบผิด

การทดสอบ	ผล	หมายเหตุ
ความถูกต้องผ่าน Tax Agent	26/26	ไม่มีข้อผิดพลาด ช่วงความเชื่อมั่นของอัตราผิดพลาดอยู่ที่ 0—12.9%
ใช้เครื่องมือคำนวณ	8/8	ถูกต้องทุกกรณี
ไม่ใช้เครื่องมือ (อ่านด้วยมือ)	7/8	ผิดกรณีเพดานรวม RMF กับ SSF (ตอบ 467,000 แทน 407,000 บาท) และยังใช้เพดานประกันสังคม 9,000 บาทแบบเก่า
การตรวจข้อมูลผิด 10 กรณี	10/10	ระบบตรวจอัตโนมัติให้ 9/10 แต่เมื่ออ่านแล้วกรณีที่ไม่ผ่านตอบถูกต้อง

ข้อสรุป ยังควรใช้เครื่องมือคำนวณภาษี ไม่ใช่เพราะโมเดลคิดเลขไม่ได้ แต่เพราะเครื่องมือทำให้ทุกคำตอบถูกต้องและเป็นกฎปัจจุบันเสมอ

7 ปัญหาที่พบจากการประเมินและแก้ไขแล้ว

- คำถาม เช่น “จ่ายเบี้ยประกันแล้ว ต้องเสียภาษีเท่าไร” ถูกส่งไป Expense Agent หลังเพิ่มหมวดประกันชีวิต แก้โดยเพิ่มกฎและตัวอย่างในคำสั่งของ Router หลังแก้ ส่งถูกไป Tax Agent 18 จาก 18 ครั้ง
- คำทักทายบางครั้งได้รับเมนูถามกลับ ปัจจุบันส่งไป General Chat แล้ว
- ชุดทดสอบเปรียบเทียบการใช้เครื่องมืออ่านคำตอบของ Gemini ไม่ได้ เพราะแปลงรูปแบบข้อความผิด แก้ไขแล้ว
- เมื่อ Agent ตอบว่างในคำถามหลายหัวข้อ ระบบแสดงหัวข้อเปล่า ปัจจุบันแสดงข้อความขออภัยแทน
- เปลี่ยนโมเดลเวกเตอร์สำรองบนเครื่องจาก MiniLM เป็น bge-m3

8 ข้อจำกัด

- ไม่ได้ทดสอบสถาปัตยกรรมซ้ำบน Gemini 3.5 Flash ด้วยข้อจำกัดด้านงบประมาณ คณะผู้จัดทำเลือก Gemini สำหรับระบบจริงเพราะเสถียรที่สุดในการทดสอบที่ใช้ Gemini คือ ภาษีถูก 26 จาก 26 กรณี จำแนกคำถาม 185 ข้อโดยไม่มีครั้งใดล้มเหลว และไม่พบคำตอบว่าง ขณะที่ DeepSeek ตอบว่างเป็นระยะ และ gpt-oss:20b เคยถามกลับเป็นภาษาจีน

- ผลของการแยกหลายเจตนาในคำถามข้ามหัวข้อเป็นค่าประมาณ
- ชุดข้อมูลทั้งหมดเขียนขึ้นเอง ไม่ได้มาจากข้อความของผู้ใช้จริง
- ยังไม่มีการประเมินโดยผู้เชี่ยวชาญ การทดสอบกับผู้ใช้จริง หรือการทดสอบเชิงโจมตี
- เวลาตอบวัดจากเครื่องของคณะผู้จัดทำ ไม่ได้วัดจากเซิร์ฟเวอร์จริง