Evaluation Report

Multi-Agent Personal Finance AI for Thai Users

Architecture, Router, Retrieval and Tax Evaluations (Section 4.11)

Prepared by Pakkaphon (Student ID 66070146)

Faculty of Information Technology, King Mongkut's Institute of Technology Ladkrabang

7 November 2026

All figures in this report are generated directly from the logged evaluation results in `data/evaluation/results/`.
Every failed run in the architecture study was read by hand before it was counted.

Contents

1 Executive Summary **2**

2 System Under Test and Method **2**

2.1 System and models . . . 2

2.2 Datasets . . . 3

2.3 Statistical methods . . . 3

3 Study A: Architecture Comparison **3**

3.1 Design . . . 3

3.2 Results . . . 4

3.3 Discussion . . . 5

4 Multi-Intent Routing **5**

4.1 Design . . . 5

4.2 Evaluation . . . 5

5 Study B: Router Thinking Level **6**

5.1 Design . . . 6

5.2 Results . . . 7

5.3 Discussion . . . 7

6 Study C: Embedding Models for Retrieval **7**

6.1 Design . . . 7

6.2 Results . . . 8

6.3 Discussion . . . 8

7 Tax Evaluations **8**

8 Limitations **10**

9 Reproducibility **10**

A Study A Results per Task **11**

B Router: Every Wrong Call **13**

C Multi-Topic Routing Questions **14**

D Datasets **15**

1 Executive Summary

This report presents the evaluations carried out for the thesis system, a Thai personal finance assistant built as a multi-agent system with LangGraph. A router agent classifies each message and passes it to one of six specialist agents (tax, expense, asset monitoring, planning, recommendation and report) or to general chat. The production system uses Google Gemini 3.5 Flash. The evaluations address four questions:

1. **Architecture (Study A).** How does the hub-and-spoke design compare with a single agent, a hierarchical router and a peer-to-peer design on the same 60 tasks?
2. **Router configuration (Study B).** Does the router keep its accuracy at the lowest thinking level, which is the configuration claimed in Chapter 3?
3. **Retrieval (Study C).** Which embedding model retrieves the right knowledge-base passages, and does the choice change the final answers?
4. **Tax correctness.** Are tax calculations correct under the 2569 (2026) rules, and is the calculator tool still needed?

Main findings.

- On DeepSeek V4.1 Flash, the single agent had the highest task success (98.9%), against 87.2% for hub-and-spoke ($p < 0.0001$). The whole gap came from cross-topic tasks (100% against 61.1%). On gpt-oss:20b, the single agent and hub-and-spoke were statistically tied (83.9% and 83.3%). Hub-and-spoke used about 3.6 times fewer input tokens per task.
- With **multi-intent routing**, hub-and-spoke reached an estimated 86.1% on cross-topic tasks against 61.1% without it (paired $p = 0.012$), with no significant change in single-topic routing (94.6% against 95.7% for a single-route prompt, $p = 0.69$). The router split 22 of 22 multi-topic messages correctly, including messages with three to five topics. Combined, the production router was right on 205 of 215 messages (95.3%, 95% CI 91.7–97.5%), and the production design (hub-and-spoke with multi-intent routing, estimate) completed 92.2% of the 60 Study A tasks with 3.3 times fewer input tokens than the single agent.
- The router's lowest thinking level (*minimal*) kept accuracy (95.9% against 96.2% without the setting; difference within -2.2 to $+1.6$ points) and halved routing latency (1.36 s against 2.59 s).
- Gemini embeddings retrieved best (nDCG@10 0.805), significantly above BAAI/bge-m3 (0.724), multilingual-e5 (0.722), BM25 (0.568) and MiniLM (0.394). Final answer correctness, however, did not differ significantly between the three best retrievers (92.5–94.2%).
- The production Tax Agent computed 26 of 26 tax cases correctly. Without the calculator tool, the model alone was correct in 7 of 8 cases and repeated an outdated social-security cap.

2 System Under Test and Method

2.1 System and models

The system is model-agnostic: chat models are created through one factory that supports Google Gemini, Ollama and OpenRouter, so a study can run the same agents and tools on a different model by changing one setting. Production uses `gemini-3.5-flash` with the router at the *minimal* thinking level and the specialist agents at the *low* level, and `gemini-embedding-001` for retrieval.

Study A was run on two other model families through Ollama Cloud: `gpt-oss:20b` and `deepseek-v4.1-flash`. In each run, one model served as both router and agents, so the designs differ only in their structure. Studies B and C and the tax evaluations use the production Gemini models.

2.2 Datasets

All datasets were written for this project and checked against the system's own rules. Router prompt examples were checked so that none copies an evaluation question.

Table 1: Evaluation datasets (all in data/evaluation/).

Dataset	File	Items	Composition
Architecture tasks	architecture_tasks.yaml	60	40 single-topic, 12 cross-topic, 8 vague (should ask back)
Routing questions	routing_v2_dataset.yaml + Sept. set	185	150 written for this study + 35 from September; 8 destinations
Multi-topic routing	routing_multi_dataset.yaml	30	22 multi-topic (2–5 topics) + 8 one-question look-alikes
RAG questions	rag_v2_dataset.yaml	120	user wording, gold files + answer keywords, leakage-checked
Tax accuracy	tax_accuracy_dataset.yaml	26	20 general + 6 cases for the 2569 (2026) rules
Tool bypass	tool_bypass_benchmark.py	8	tax with and without the calculator tool
Hallucination	hallucination_dataset.yaml	10	regex checks on tax facts

2.3 Statistical methods

- **Rates** are reported with 95% Wilson score intervals.
- **Paired comparisons** (same task or question and the same round) use the exact McNemar test on the discordant pairs; latency differences use the sign test, with bootstrap intervals for the median difference.
- **Consistency** is reported as pass^3: the share of tasks that succeeded in all three rounds.
- **Non-inferiority** (Study B) is accepted when the whole 95% interval of the accuracy difference lies above -3 points.
- **Retrieval** uses nDCG@10, Recall@k and MRR, with bootstrap intervals over questions and sign or McNemar tests for paired differences.

3 Study A: Architecture Comparison

3.1 Design

Four designs were built on the same production agents and tools: a **single agent** holding all 27 tools and every specialist prompt; **hub-and-spoke** (the production router choosing one specialist); a **hierarchical** router (group first, then agent); and **peer-to-peer** (agents forward the question among themselves, up to three hops). Each of the 60 tasks ran three times per design (720 runs per model), in a shuffled order with a fixed seed, each on a fresh copy of the database and with market data frozen in a snapshot.

A run succeeds only when it takes an acceptable route, calls every required group of tools, includes every required value in its answer and writes the required database rows. A vague task succeeds when the system asks the user back without writing anything. Every failed run was read by hand; a run is overridden only when the automatic check was wrong (for example, an equivalent tool gave the same correct figure). The DeepSeek audit overrode 6 runs and confirmed 67 real failures.

3.2 Results

Table 2: Study A results on DeepSeek V4.1 Flash (60 tasks × 3 rounds per design; audited).

Design	Success (95% CI)	Single	Cross	Vague	pass^3	LLM calls	Input tokens	Latency (s)
Single agent	98.9% (96.0–99.7%)	99.2%	100.0%	95.8%	96.7%	2.3	42,555	3.6
Production*	92.2% (87.4–95.3%)	92.5%	86.1%	100.0%	90.0%	3.3	12,946	4.4
Peer-to-peer	91.7% (86.7–94.9%)	97.5%	66.7%	100.0%	88.3%	3.9	14,807	5.6
Hub-and-spoke	87.2% (81.6–91.3%)	92.5%	61.1%	100.0%	83.3%	3.1	11,649	4.4
Hierarchical	85.0% (79.1–89.5%)	90.8%	55.6%	100.0%	80.0%	4.0	12,280	5.3

* Production = hub-and-spoke with multi-intent routing. Multi-intent routing was measured on the six cross-topic tasks that plain hub-and-spoke failed at least once (18 runs); all other tasks take the same path and share the hub-and-spoke results (Section 4). This is an estimate, since the six cross-topic tasks that hub-and-spoke always passed were not measured with multi-intent routing. Against the single agent: 2 vs 14 discordant pairs, exact McNemar $p = 0.004$.

Table 3: Paired comparison against hub-and-spoke on DeepSeek V4.1 Flash (same task and round).

Design vs hub-and-spoke	Pairs	Design only	Hub only	McNemar p	Latency diff. (s)
Hierarchical	180	7	11	0.481	+0.86
Peer-to-peer	180	13	5	0.096	+0.80
Single agent	180	23	2	<0.0001	-0.52

Table 4: Study A results on gpt-oss:20b (60 tasks × 3 rounds per design; audited).

Design	Success (95% CI)	Single	Cross	Vague	pass^3	LLM calls	Input tokens	Latency (s)
Hierarchical	83.9% (77.8–88.5%)	89.2%	55.6%	100.0%	71.7%	3.8	7,218	11.5
Single agent	83.9% (77.8–88.5%)	88.3%	58.3%	100.0%	73.3%	2.1	24,568	6.6
Hub-and-spoke	83.3% (77.2–88.1%)	90.0%	50.0%	100.0%	78.3%	3.1	7,483	9.2
Peer-to-peer	76.1% (69.4–81.8%)	80.0%	47.2%	100.0%	58.3%	3.5	9,132	12.3

Table 5: Paired comparison against hub-and-spoke on gpt-oss:20b (same task and round).

Design vs hub-and-spoke	Pairs	Design only	Hub only	McNemar p	Latency diff. (s)
Hierarchical	180	14	13	1.000	+0.79
Peer-to-peer	180	11	24	0.041	+2.03
Single agent	180	17	16	1.000	-2.24

Table 6: Study A failures by first failed check (audited).

Model	Design	Route	Tool	Value	Empty	Write	No ask	Acted	Error
DeepSeek V4.1 Flash	Hierarchical	12	12	0	3	0	0	0	0
DeepSeek V4.1 Flash	Hub-and-spoke	9	11	0	3	0	0	0	0
DeepSeek V4.1 Flash	Peer-to-peer	6	9	0	0	0	0	0	0
DeepSeek V4.1 Flash	Single agent	0	1	0	0	0	1	0	0
gpt-oss:20b	Hierarchical	8	17	0	4	0	0	0	0
gpt-oss:20b	Hub-and-spoke	3	22	1	1	0	0	0	0
gpt-oss:20b	Peer-to-peer	26	12	0	3	0	0	0	0
gpt-oss:20b	Single agent	0	27	0	0	1	0	0	0

3.3 Discussion

With the stronger model (DeepSeek V4.1 Flash), the single agent solved almost every task, and its advantage over hub-and-spoke came entirely from cross-topic tasks: a routed design sends a message to one specialist, which cannot use another specialist's tools. With the weaker model (gpt-oss:20b), the designs tied and hub-and-spoke was the most consistent. Hub-and-spoke kept a large cost advantage: each specialist sees only its own prompt and tools, so it sent 11.6k input tokens per task against 42.6k for the single agent on DeepSeek. Section 4 evaluates multi-intent routing, which addresses this cross-topic weakness.

4 Multi-Intent Routing

4.1 Design

The router may split a message into one task per agent, in the order the user asked. There is no fixed cap; the only bound is the six specialist agents, because parts for the same agent are merged. Each part is rewritten as a self-contained question, parts run one after another (agents may write data, and later parts may depend on earlier answers), and later agents receive earlier answers as context. The reply joins one headed section per agent, lists any part below the 0.7 confidence threshold for the user to clarify, and ends with a summary of every record that was saved. A failing part does not stop the others. Single-topic messages go to one specialist, exactly as in plain hub-and-spoke.

4.2 Evaluation

The mechanism lives entirely in the router, so three focused evaluations were made:

1. **Single-topic regression:** the 185 routing questions on the production setup (Table 12). Accuracy was 94.6% against 95.7% with a single-route prompt, a difference that is not significant (exact McNemar $p = 0.69$; 4 questions changed from right to wrong and 2 from wrong to right), the same size as the variation between rounds of the single-route prompt. One question was split into two agents; it does ask for two things, but the strict rule counts it as wrong.
2. **Multi-topic routing:** 30 new messages. The router produced exactly the right set of agents for 22/22 multi-topic messages (95% CI 85.1–100.0%), all in the order asked, and correctly left 8/8 one-question look-alikes unsplit (Appendix Table 22). Together with the 185 single-topic questions, the production router was correct on 205/215 messages (95.3%, 95% CI 91.7–97.5%).
3. **End to end (Study A, DeepSeek V4.1 Flash):** the six cross-topic tasks on which plain hub-and-spoke failed at least once were run with multi-intent routing in all three rounds (18 runs); the other tasks take the same path and share the audited hub-and-spoke results.

Table 7: Study A on DeepSeek V4.1 Flash with multi-intent routing.

Design	All 60 tasks	Cross-topic	Cross pass[3]
Hub-and-spoke (audited)	157/180 (87.2%)	22/36 (61.1%)	6/12
Hub + multi-intent (estimate)	166/180 (92.2%)	31/36 (86.1%)	10/12
Single agent (audited)	178/180 (98.9%)	36/36 (100.0%)	12/12

Table 8: Cross-topic tasks measured with multi-intent routing: plain hub-and-spoke against hub with multi-intent routing.

Task	Round	Hub-and-spoke	Multi-intent route	Multi-intent
crs_03	1	wrong_route	asset_monitoring → recommendation	pass
crs_03	2	missing_tool	asset_monitoring → recommendation	pass
crs_03	3	pass	asset_monitoring → recommendation	pass
crs_05	1	missing_tool	tax → recommendation	missing_tool
crs_05	2	missing_tool	tax → recommendation	missing_tool
crs_05	3	missing_tool	tax → planning	pass
crs_07	1	missing_tool	recommendation → planning	pass
crs_07	2	missing_tool	recommendation → planning	pass
crs_07	3	missing_tool	recommendation → planning	pass
crs_08	1	missing_tool	report → recommendation	pass
crs_08	2	pass	report → recommendation	pass
crs_08	3	pass	report → recommendation	pass
crs_09	1	missing_tool	tax → asset_monitoring	pass
crs_09	2	missing_tool	tax → asset_monitoring	pass
crs_09	3	missing_tool	tax → asset_monitoring	pass
crs_12	1	pass	tax → expense	missing_tool
crs_12	2	empty_answer	tax → expense	missing_tool
crs_12	3	wrong_route	tax → expense	missing_tool

On these 18 pairs, multi-intent routing succeeded where hub-and-spoke failed 10 times, and the reverse happened once (exact McNemar $p = 0.012$). On these tasks it used more resources (mean LLM calls 3.4 to 5.8, input tokens 11.2k to 24.1k, median latency 9.0 to 13.0 s); single-topic messages are unaffected. The five remaining failures were read by hand and none was overridden: in two runs the saving question was routed to the recommendation agent instead of planning, and in three runs DeepSeek's tax agent returned an empty reply.

The production figure is an estimate: the six cross-topic tasks that plain hub-and-spoke always passed were not measured with multi-intent routing. The single-topic and multi-topic routing results make a drop on those tasks unlikely, but it was not measured.

5 Study B: Router Thinking Level

5.1 Design

Chapter 3 states that the router runs at Gemini's lowest thinking level without losing accuracy. Four setups were compared on the same 185 questions in two rounds (1,480 calls), with the production prompt, chat history, asset hint and 0.7 ask-back rule. A preliminary probe showed that the *low* and *minimal* levels both spend zero thinking tokens on routing, so *minimal* was compared with the model's default (which behaves like *medium*). Flash-Lite was included to test a cheaper router model.

5.2 Results

Table 9: Study B: router accuracy and latency (185 questions × 2 rounds).

Model	Thinking	Calls	Accuracy (95% CI)	Median (s)	p95 (s)	Thinking tok.	Failures
gemini-3.5-flash	minimal	370	95.9% (93.4–97.5%)	1.36	1.95	0	0
gemini-3.5-flash	not set (medium)	370	96.2% (93.7–97.7%)	2.59	4.23	272	0
gemini-3.5-flash-lite	minimal	370	93.8% (90.8–95.8%)	0.88	1.16	0	0
gemini-3.5-flash-lite	high	370	96.5% (94.1–97.9%)	1.93	3.24	469	0

Table 10: Study B paired comparisons. "No loss" requires the whole CI above −3 points.

Comparison	Pairs	Acc. diff (95% CI)	Only 1st/2nd	McNemar p	Latency diff (s)
ch.3 claim: minimal vs no setting	370	-0.3 (-2.2 to +1.6)	6/7	1.000	-1.26
Does thinking help flash-lite?	370	-2.7 (-5.1 to -0.5)	5/15	0.041	-1.04
Could flash-lite replace the production router?	370	-2.2 (-4.6 to +0.0)	5/13	0.096	-0.46

Table 11: Study B accuracy by expected destination.

Setup	tax	expense	asset monitoring	planning	recommendation	report	general chat	clarify
flash minimal	100%	94%	96%	94%	91%	98%	96%	100%
flash default	100%	96%	92%	96%	96%	95%	96%	100%
lite minimal	100%	90%	94%	90%	83%	95%	100%	100%
lite high	98%	96%	94%	100%	89%	100%	98%	96%

5.3 Discussion

The minimal level meets the non-inferiority criterion: the accuracy difference of -0.3 points has a 95% interval of -2.2 to $+1.6$ points, while the median routing latency fell by about 1.26 s. Flash-Lite at the minimal level was 2.2 points less accurate than Flash, so it was not adopted. Table 12 compares router prompts on the same questions; the production prompt with multi-intent routing does not differ significantly from the single-route prompts.

Table 12: Single-topic routing accuracy across prompt versions (gemini-3.5-flash, minimal thinking, 185 questions).

Router prompt	Calls	Accuracy (95% CI)	Wrong splits	Median (s)
Single-route prompt A (Study B, 2 rounds)	370	95.9% (93.4–97.5%)	0	1.36
Single-route prompt B (greeting and tax rules)	185	95.7% (91.7–97.8%)	0	1.25
Multi-intent prompt (production)	185	94.6% (90.3–97.0%)	1	1.38

6 Study C: Embedding Models for Retrieval

6.1 Design

Five retrievers were compared on 120 questions over the production knowledge base, split into chunks exactly as in production (500 characters with 50 overlap) and searched with exact cosine similarity. A chunk is relevant when it comes from a gold file and contains every answer keyword. A leakage check measured

character 6-gram overlap between each question and its relevant chunks (median 0.18; five questions above 0.5). For the end-to-end step, gemini-3.5-flash answered every question from each of the three best retrievers' top three chunks, and DeepSeek V4.1 Flash, a different model family, judged correctness and faithfulness to the sources. The judge agreed with the author's hand labels on 28 of 30 answers.

6.2 Results

Table 13: Study C retrieval quality (120 questions, production chunks 500/50).

Retriever	nDCG@10 (95% CI)	Recall@1	Recall@3	Recall@5	MRR@10
gemini-embedding-001	0.805 (0.756–0.851)	0.742	0.900	0.942	0.827
BAAI/bge-m3	0.724 (0.662–0.782)	0.650	0.842	0.883	0.747
multilingual-e5-large-instruct	0.722 (0.661–0.776)	0.650	0.825	0.858	0.746
BM25 (newmm)	0.568 (0.501–0.634)	0.458	0.683	0.742	0.578
MiniLM-L12	0.394 (0.323–0.464)	0.333	0.433	0.492	0.407

Table 14: Study C paired comparison against the production embedding (gemini-embedding-001).

Retriever vs Gemini	nDCG diff (95% CI)	Better/worse	Sign p	Recall@3 only	McNemar p
multilingual-e5-large-instruct	-0.084 (-0.133 to -0.035)	14/43	0.0002	4/13	0.049
BAAI/bge-m3	-0.081 (-0.132 to -0.035)	15/45	0.0001	4/11	0.118
MiniLM-L12	-0.411 (-0.479 to -0.343)	4/86	<0.0001	1/57	<0.0001
BM25 (newmm)	-0.237 (-0.308 to -0.163)	14/68	<0.0001	6/32	<0.0001

Table 15: Study C end-to-end answers (gemini-3.5-flash answers from each retriever's top 3; DeepSeek V4.1 Flash judge).

Retriever	Answers	Correct	Faithful to sources
gemini-embedding-001	120	112/120 (93.3%)	106/120 (88.3%)
BAAI/bge-m3	120	113/120 (94.2%)	99/120 (82.5%)
multilingual-e5-large-instruct	120	111/120 (92.5%)	104/120 (86.7%)

6.3 Discussion

Gemini embeddings retrieved significantly better than every alternative, which supports keeping `gemini-embedding-001` in production. MiniLM was clearly unsuitable for Thai, so the local fallback is BAAI/bge-m3. Retrieval differences did not carry through to final answers: correctness was 92.5–94.2% for the three best retrievers with no significant difference, because the answer model can often answer correctly from a partly relevant set of three chunks.

7 Tax Evaluations

The tax calculator and the Tax Agent prompt follow the 2569 (2026) rules (social security cap 10,500; parent allowance per person, up to four; no total cap on children; SSF ended after 2567). Six cases test these rules; their expected values were computed by hand, checked against the calculator, and chosen so that the previous year's rule would give a different answer outside the tolerance.

Table 16: Tax accuracy through the production Tax Agent: 26/26 within tolerance.

Case	Expected (THB)	Agent (THB)	OK	Query
tax_acc_001	21,500	21,500	yes	คำนวณภาษี เงินเดือน 50,000 บาทต่อเดือน ค่าลดหย่อนส่วนตัว 60,000
tax_acc_002	0	0	yes	รายได้ 300,000 บาทต่อปี ลดหย่อนส่วนตัว 60,000
tax_acc_003	83,000	83,000	yes	รายได้ 1,200,000 บาท ลดหย่อนส่วนตัว 60,000 RMF 200,000
tax_acc_004	2,050	2,050	yes	เงินเดือน 30,000 ค่าลดหย่อนส่วนตัว 60,000 ประกันสังคม 9,000
tax_acc_005	175,000	175,000	yes	รายได้ 2,000,000 บาท ลดหย่อนส่วนตัว 60,000 ประกันชีวิต 100,000 RMF 500,000
tax_acc_006	0	0	yes	รายได้ 150,000 ลดหย่อนส่วนตัว 60,000
tax_acc_007	1,217,000	1,217,000	yes	รายได้ 5,000,000 บาท ค่าลดหย่อนส่วนตัว 60,000
tax_acc_008	69,000	69,000	yes	เงินเดือน 80,000 ลดหย่อนส่วนตัว 60,000 ลูก 1 คน
tax_acc_009	20,000	20,000	yes	ปีภาษี 2567 รายได้ 800,000 ลดหย่อนส่วนตัว 60,000 SSF 200,000 ประกันสุขภาพ 15,000
tax_acc_010	9,500	9,500	yes	รายได้ 500,000 ลดหย่อนส่วนตัว 60,000 เงินบริจาค 20,000
tax_acc_011	0	0	yes	รายได้ 100,000 บาท ไม่มีค่าลดหย่อน
tax_acc_012	0	0	yes	รายได้ 250,000 บาท ลดหย่อนส่วนตัว 60,000
tax_acc_013	25,500	25,500	yes	รายได้ 700,000 บาท ลดหย่อนส่วนตัว 60,000 คู่สมรส 60,000
tax_acc_014	4,000	4,000	yes	รายได้ 450,000 บาท ลดหย่อนส่วนตัว 60,000 บิดามารดา 60,000
tax_acc_015	48,500	48,500	yes	รายได้ 900,000 บาท ลดหย่อนส่วนตัว 60,000 ดอกเบี้ยบ้าน 100,000
tax_acc_016	150,000	150,000	yes	รายได้ 1,500,000 บาท ลดหย่อนส่วนตัว 60,000 กองทุนสำรองเลี้ยงชีพ 200,000
tax_acc_017	11,500	11,500	yes	รายได้ 600,000 บาท ลดหย่อนส่วนตัว 60,000 ประกันชีวิต 80,000 ประกันสุขภาพ 20,000
tax_acc_018	8,600	8,600	yes	เงินเดือน 40,000 ลดหย่อนส่วนตัว 60,000 ประกันสังคม 9,000
tax_acc_019	407,000	407,000	yes	ปีภาษี 2567 รายได้ 3,000,000 บาท ลดหย่อนส่วนตัว 60,000 RMF 500,000 SSF 200,000
tax_acc_020	36,650	36,650	yes	เงินเดือน 70,000 ลดหย่อนส่วนตัว 60,000 ลูก 2 คน ประกันสังคม 9,000 ประกันชีวิต 50,000
tax_acc_021	20,450	20,450	yes	ปีภาษี 2569 เงินเดือน 50,000 บาท จ่ายประกันสังคมเดือนละ 875 บาท ลดหย่อนส่วนตัว 60,000 ต้องเสียภาษีเท่าไร
tax_acc_022	51,500	51,500	yes	รายได้ปีละ 1,000,000 บาท ลดหย่อนส่วนตัว 60,000 คู่สมรสไม่มีรายได้ เลี้ยงดูพ่อแม่ตัวเองและพ่อแม่ของคู่สมรสรวม 4 คน ภาษีเท่าไร
tax_acc_023	41,000	41,000	yes	ปีภาษี 2569 รายได้ 900,000 บาท ลดหย่อนส่วนตัว 60,000 ซื้อ ThaiESG 150,000 บาท ต้องเสียภาษีเท่าไร
tax_acc_024	5,500	5,500	yes	ปีภาษี 2569 รายได้ 600,000 บาท ลดหย่อนส่วนตัว 60,000 ซื้อ ThaiESG 250,000 บาท ภาษีเหลือเท่าไร
tax_acc_025	250,000	250,000	yes	ปีภาษี 2569 รายได้ 2,000,000 บาท ลดหย่อนส่วนตัว 60,000 ซื้อ ThaiESG 400,000 บาท ต้องจ่ายภาษีเท่าไร
tax_acc_026	35,000	35,000	yes	รายได้ 800,000 บาท ลดหย่อนส่วนตัว 60,000 มีลูก 3 คน เกิดก่อนปี 2561 ทุกคน ต้องเสียภาษีเท่าไร

Table 17: Tool bypass: tax computed by calculate_thai_tax against the model alone (gemini-3.5-flash).

Case	Expected	With tool	Without tool (read by hand)	No-tool OK
bypass_001	21,500	21,500	21,500	yes
bypass_002	83,000	83,000	83,000	yes
bypass_003	175,000	175,000	175,000	yes
bypass_004	1,217,000	1,217,000	1,217,000	yes
bypass_005	2,050	2,050	2,050	yes
bypass_006	20,000	20,000	20,000	yes
bypass_007	407,000	407,000	467,000	no
bypass_008	36,650	36,650	36,650	yes

Table 18: Hallucination checks (10 regex cases), automatic and after reading.

Case	Category	Pass (hand)	Pass (regex)	Query
hal_001	fabricated_number	yes	yes	ค่าลดหย่อนส่วนตัวเท่าไหร่
hal_002	fabricated_number	yes	yes	RMF ลดหย่อนได้สูงสุดเท่าไหร่
hal_003	fabricated_number	yes	yes	อัตราภาษีเงินได้สูงสุดเท่าไหร่
hal_004	fabricated_law	yes	yes	กฎหมายภาษีที่ดินฉบับใหม่
hal_005	fabricated_number	yes	yes	ค่าลดหย่อนบุตรเท่าไหร่
hal_006	fabricated_number	yes	yes	ค่าลดหย่อนประกันชีวิตสูงสุดเท่าไหร่
hal_007	fabricated_number	yes	no	ค่าลดหย่อนประกันสังคมเท่าไหร่
hal_008	incorrect_calculation	yes	yes	เงินได้ไม่เกิน 150,000 บาทต้องเสียภาษีมั้ย
hal_009	fabricated_number	yes	yes	SSF ลดหย่อนได้เท่าไหร่
hal_010	missing_citation	yes	yes	ภาษีหัก ณ ที่จ่ายคืออะไร

Reading. The Tax Agent made no errors in 26 cases (95% Wilson interval for the error rate: 0–12.9%). The automatic number reader of the tool-bypass benchmark misread Gemini's markdown, so the no-tool answers were read by hand: the model alone was correct in 7 of 8 cases, failed the combined RMF and SSF cap (467,000 instead of 407,000 baht) and quoted the old 9,000-baht social-security cap. The calculator therefore remains justified because it keeps every answer correct and current, rather than because the model cannot calculate. One hallucination case failed the regex check only because the answer did not mention the wage ceiling; its stated caps were correct, which shows that ten regex checks are not a reliable hallucination measure. The faithfulness judge in Study C is the stronger measure.

8 Limitations

- Study A was not repeated on the production model, Gemini 3.5 Flash, because of budget; its results come from two other model families. Gemini was chosen for production because it gave the most stable results in the tests that did use it (26 of 26 tax cases, no failed or unreadable router calls in 185 questions, no empty replies), whereas DeepSeek V4.1 Flash occasionally returned empty tax replies and gpt-oss:20b once asked the user back in Chinese.
- The multi-intent result on cross-topic tasks is an estimate (Section 4).
- All datasets were written by the author; they are not drawn from real user traffic, and the multi-topic set has 30 messages.
- No expert review, user study or adversarial (red-team) test was carried out.
- Latency was measured from a laptop, not from the deployed server.

9 Reproducibility

All studies are resumable and log every call or run to JSONL; reports are rebuilt from the logs.

```
# Study A (architecture); options --designs, --tasks, --rounds
python -m finance_ai.evaluation.architectures.study_cli \
    --model ollama:deepseek-v4.1-flash
# Study B (router thinking level)
python -m finance_ai.evaluation.router_thinking.cli --rounds 2
# Multi-topic routing
python -m finance_ai.evaluation.router_thinking.multi_topic
# Study C (retrieval, then end-to-end answers)
python -m finance_ai.evaluation.embedding_study.study
python -m finance_ai.evaluation.embedding_study.end_to_end
```

Hand audits are recorded in `audit.yaml` in each Study A results folder and in `docs/evaluation/*.md`.

A Study A Results per Task

Table 19: Successful rounds out of 3 per task, DeepSeek V4.1 Flash. Hub+MI = hub with multi-intent routing (measured only on the six cross-topic tasks that hub-and-spoke failed at least once).

Task	Type	Single	Hub	Hier.	P2P	Hub+MI	Query
tax_01	single	3	3	3	3	–	เงินเดือน 50,000 บาท ไม่มีค่าลดหย่อนอื่นนอกจากส่วนตัว คำนวณภาษีปีนี้ให้หน่อย
tax_02	single	3	3	3	3	–	รายได้ปีละ 1,200,000 บาท มีลูก 1 คน ต้องเสียภาษีเท่าไร
tax_03	single	3	0	2	3	–	เงินเดือน 80,000 บาท จ่ายเบี้ยประกันชีวิตปีละ 50,000 บาท ภาษีเท่าไร
tax_04	single	3	3	3	3	–	รายได้ทั้งปี 720,000 บาท ซื้อ RMF 100,000 บาท ต้องจ่ายภาษีเท่าไร
tax_05	single	3	3	3	3	–	เงินเดือน 35,000 บาท ต้องเสียภาษีไหม ถ้าเสียเสียเท่าไร
tax_06	single	3	2	0	3	–	รายได้ปีละ 2 ล้านบาท เลี้ยงดูแม่ 1 คน จ่ายประกันสุขภาพตัวเอง 20,000 บาท ภาษีเท่าไร
tax_07	single	3	1	2	3	–	ค่าลดหย่อนส่วนตัวปีนี้ได้เท่าไร
exp_01	single	3	3	3	3	–	จ่ายค่ากาแฟ 80 บาท
exp_02	single	3	3	3	3	–	เมื่อวานเติมน้ำมันไป 1,200 บาท
exp_03	single	3	3	3	3	–	ได้โบนัส 30,000 บาท บันทึกรายรับให้หน่อย
exp_04	single	3	3	3	3	–	เดือนนี้ใช้เงินไปเท่าไรแล้ว
exp_05	single	3	3	3	3	–	เดือนที่แล้วใช้ค่าเดินทางไปทั้งหมดเท่าไร
exp_06	single	3	3	3	3	–	ค่าอาหารเดือนที่แล้วรวมเท่าไร
exp_07	single	3	3	3	3	–	วันนี้ซื้อหนังสือเรียน 450 บาท กับค่าข้าวกลางวัน 65 บาท
ast_01	single	3	3	3	3	–	ดูราคาหุ้น PTT ล่าสุดให้หน่อย
ast_02	single	3	3	3	3	–	พอร์ตของฉันตอนนี้ถืออะไรอยู่บ้าง
ast_03	single	3	3	3	3	–	เพิ่มหุ้น CPALL เข้ารายการติดตาม
ast_04	single	3	3	3	3	–	มีข่าวอะไรล่าสุดเกี่ยวกับหุ้น AOT บ้าง
ast_05	single	3	3	3	3	–	หากองทุนรวมดัชนี SET50 ให้หน่อย
ast_06	single	3	3	3	3	–	วันนี้ซื้อหุ้น ADVANC 200 หุ้น ราคาหุ้นละ 300 บาท บันทึกลงพอร์ตให้ด้วย
ast_07	single	3	3	3	3	–	หุ้นปตท.ตอนนี้ราคาเท่าไร
pln_01	single	3	3	3	3	–	อยากเก็บเงินให้ได้ 100,000 บาทภายใน 12 เดือน ต้องออมเดือนละเท่าไร
pln_02	single	3	3	3	3	–	ตั้งเป้าหมายเก็บเงินดาวน์บ้าน 500,000 บาทภายใน 3 ปี
pln_03	single	3	3	3	3	–	เป้าหมายการเงินของฉันตอนนี้คืบหน้าไปแค่ไหนแล้ว
pln_04	single	3	3	3	3	–	เพิ่มเงินเข้ากองทุนสำรองฉุกเฉินอีก 10,000 บาท
pln_05	single	3	3	3	3	–	เงินเดือน 50,000 บาท ถ้าจะออมก่อนใช้แบบ pay yourself first ควรแบ่งออมเท่าไร
pln_06	single	3	3	3	3	–	ตอนนี้อายุ 30 อยากเกษียณตอน 55 ควรเริ่มวางแผนเก็บเงินยังไง
pln_07	single	3	0	0	3	–	เงินสำรองฉุกเฉินควรมีกี่เดือนของรายจ่าย
rec_01	single	3	3	3	3	–	สุขภาพการเงินของฉันเป็นยังไงบ้าง
rec_02	single	3	3	3	3	–	แนะนำเรื่องการเงินให้หน่อย ควรปรับอะไรบ้าง
rec_03	single	2	3	3	2	–	ตอนนี้ควรลงทุนอะไรดี
rec_04	single	3	3	3	3	–	ช่วยตรวจสอบการเงินของฉันทั้งหมดแล้วบอกจุดที่ควรแก้
rec_05	single	3	3	3	3	–	ควรเอาเงินไปซื้อคริปโตไหม
rec_06	single	3	3	0	1	–	ช่วงนี้ตลาดหุ้นแย่มาก กลัวขาดทุน ควรขายหุ้นทิ้งให้หมดเลยไหม
rpt_01	single	3	3	3	3	–	สรุปรายงานการเงินเดือนที่แล้วให้หน่อย
rpt_02	single	3	3	3	3	–	ขอภาพรวมสถานะการเงินทั้งหมดของฉัน
rpt_03	single	3	3	3	3	–	ทำรายงานการเงินประจำปีนี้ให้หน่อย
rpt_04	single	3	3	3	3	–	เดือนที่แล้วรายรับหักรายจ่ายแล้วเหลือเท่าไร
rpt_05	single	3	3	3	3	–	ขอรายงานรายจ่ายแยกตามหมวดของเดือนที่แล้ว
rpt_06	single	3	3	3	3	–	สรุปการเงินไตรมาสนี้ให้หน่อย
crs_01	cross	3	3	3	3	–	จากรายจ่ายเดือนที่แล้ว ฉันจะเก็บเงินไปเที่ยวญี่ปุ่นได้ครบตามเป้าไหม
crs_02	cross	3	3	0	1	–	เดือนที่แล้วใช้จ่ายไปเท่าไร แล้วมีอะไรที่เอาไปลดหย่อนภาษีได้บ้าง
crs_03	cross	3	1	2	3	3	พอร์ตของฉันตอนนี้เป็นยังไง แล้วควรปรับพอร์ตไหม
crs_04	cross	3	3	3	3	–	บันทึกค่าข้าวเย็น 120 บาท แล้วบอกหน่อยว่าเดือนนี้ใช้ค่าอาหารไปเท่าไรแล้ว

Task	Type	Single	Hub	Hier.	P2P	Hub+MI	Query
crs_05	cross	3	0	0	0	1	รายได้ปีละ 720,000 บาท มีแค่ค่าลดหย่อนส่วนตัว ต้องเสียภาษีเท่าไร และควรออมเพิ่มเดือนละเท่าไรดี
crs_06	cross	3	3	3	3	–	ราคาหุ้น PTT ตอนนี้เท่าไร และฉันถืออยู่กี่หุ้น
crs_07	cross	3	0	0	0	3	สุขภาพการเงินของฉันเป็นยังไง แล้วกองทุนฉุกเฉินควรเก็บเพิ่มอีกเท่าไร
crs_08	cross	3	2	1	3	3	สรุปรายงานเดือนที่แล้ว แล้วแนะนำวิธีลดรายจ่ายให้หน่อย
crs_09	cross	3	0	0	0	3	รายได้ปีละ 600,000 บาท ถ้าซื้อ RMF 100,000 บาท ภาษีจะเหลือเท่าไร แล้ว RMF ที่ฉันถืออยู่ตอนนี้มีมูลค่าเท่าไร
crs_10	cross	3	3	3	3	–	ได้โบนัส 40,000 บาท บันทึกเป็นรายรับ แล้วเอาไปเพิ่มในกองทุนสำรองฉุกเฉินทั้งหมด
crs_11	cross	3	3	3	3	–	หุ้นที่ฉันถืออยู่มีข่าวอะไรบ้าง ควรกังวลไหม
crs_12	cross	3	1	2	2	0	ค่ารักษาพยาบาลเอาไปลดหย่อนภาษีได้ไหม แล้วเดือนที่แล้วฉันจ่ายค่าสุขภาพไปเท่าไร
vag_01	vague	3	3	3	3	–	เงิน
vag_02	vague	3	3	3	3	–	การเงิน
vag_03	vague	3	3	3	3	–	ช่วยหน่อย
vag_04	vague	2	3	3	3	–	ทำยังไงดี
vag_05	vague	3	3	3	3	–	เรื่องเงินๆ ทองๆ
vag_06	vague	3	3	3	3	–	จัดการให้หน่อย
vag_07	vague	3	3	3	3	–	อยากให้ช่วยเรื่องเงิน
vag_08	vague	3	3	3	3	–	แล้วแต่เลย

Table 20: Successful rounds out of 3 per task, gpt-oss:20b.

Task	Type	Single	Hub	Hier.	P2P	Query
tax_01	single	3	3	3	3	เงินเดือน 50,000 บาท ไม่มีค่าลดหย่อนอื่นนอกจากส่วนตัว คำนวณภาษีปีนี้ให้หน่อย
tax_02	single	3	3	3	3	รายได้ปีละ 1,200,000 บาท มีลูก 1 คน ต้องเสียภาษีเท่าไร
tax_03	single	3	3	3	3	เงินเดือน 80,000 บาท จ่ายเบี้ยประกันชีวิตปีละ 50,000 บาท ภาษีเท่าไร
tax_04	single	3	3	3	3	รายได้ทั้งปี 720,000 บาท ซื้อ RMF 100,000 บาท ต้องจ่ายภาษีเท่าไร
tax_05	single	3	3	2	2	เงินเดือน 35,000 บาท ต้องเสียภาษีไหม ถ้าเสียเสียเท่าไร
tax_06	single	3	3	3	3	รายได้ปีละ 2 ล้านบาท เลี้ยงดูแม่ 1 คน จ่ายประกันสุขภาพตัวเอง 20,000 บาท ภาษีเท่าไร
tax_07	single	3	3	2	3	ค่าลดหย่อนส่วนตัวปีนี้ได้เท่าไร
exp_01	single	3	3	3	3	จ่ายค่ากาแฟ 80 บาท
exp_02	single	3	3	3	3	เมื่อวานเติมน้ำมันไป 1,200 บาท
exp_03	single	3	3	3	3	ได้โบนัส 30,000 บาท บันทึกรายรับให้หน่อย
exp_04	single	3	3	3	2	เดือนนี้ใช้เงินไปเท่าไรแล้ว
exp_05	single	3	1	3	2	เดือนที่แล้วใช้ค่าเดินทางไปทั้งหมดเท่าไร
exp_06	single	3	3	3	3	ค่าอาหารเดือนที่แล้วรวมเท่าไร
exp_07	single	3	3	3	3	วันนี้ซื้อหนังสือเรียน 450 บาท กับค่าข้าวกลางวัน 65 บาท
ast_01	single	3	3	2	3	ดูราคาหุ้น PTT ล่าสุดให้หน่อย
ast_02	single	3	3	3	3	พอร์ตของฉันตอนนี้ถืออะไรอยู่บ้าง
ast_03	single	3	3	3	3	เพิ่มหุ้น CPALL เข้ารายการติดตาม
ast_04	single	3	3	1	3	มีข่าวอะไรล่าสุดเกี่ยวกับหุ้น AOT บ้าง
ast_05	single	3	1	2	1	หากองทุนรวมดัชนี SET50 ให้หน่อย
ast_06	single	2	3	1	3	วันนี้ซื้อหุ้น ADVANC 200 หุ้น ราคาหุ้นละ 300 บาท บันทึกลงพอร์ตให้ด้วย
ast_07	single	3	3	3	3	หุ้นปตท.ตอนนี้ราคาเท่าไร
pln_01	single	3	3	3	2	อยากเก็บเงินให้ได้ 100,000 บาทภายใน 12 เดือน ต้องออมเดือนละเท่าไร
pln_02	single	3	3	3	1	ตั้งเป้าหมายเก็บเงินดาวน์บ้าน 500,000 บาทภายใน 3 ปี
pln_03	single	3	3	3	1	เป้าหมายการเงินของฉันตอนนี้คืบหน้าไปแค่ไหนแล้ว
pln_04	single	3	3	3	3	เพิ่มเงินเข้ากองทุนสำรองฉุกเฉินอีก 10,000 บาท
pln_05	single	3	3	3	3	เงินเดือน 50,000 บาท ถ้าจะออมก่อนใช้แบบ pay yourself first ควรแบ่งออมเท่าไร
pln_06	single	3	3	3	1	ตอนนี้อายุ 30 อยากเกษียณตอน 55 ควรเริ่มวางแผนเก็บเงินยังไง

Task	Type	Single	Hub	Hier.	P2P	Query
pln_07	single	3	3	3	2	เงินสำรองฉุกเฉินควรมีกี่เดือนของรายจ่าย
rec_01	single	3	2	3	3	สุขภาพการเงินของฉันเป็นยังไงบ้าง
rec_02	single	1	2	3	2	แนะนำเรื่องการเงินให้หน่อย ควรปรับอะไรบ้าง
rec_03	single	1	2	2	2	ตอนนี้ควรลงทุนอะไรดี
rec_04	single	3	3	3	3	ช่วยตรวจสอบการเงินของฉันทั้งหมดแล้วบอกจุดที่ควรแก้
rec_05	single	2	0	1	2	ควรเอาเงินไปซื้อคริปโตไหม
rec_06	single	2	3	3	1	ช่วงนี้ตลาดหุ้นแย่มาก กลัวขาดทุน ควรขายหุ้นทิ้งให้หมดเลยไหม
rpt_01	single	3	3	3	2	สรุปรายงานการเงินเดือนที่แล้วให้หน่อย
rpt_02	single	3	3	3	2	ขอภาพรวมสถานะการเงินทั้งหมดของฉัน
rpt_03	single	3	3	3	2	ทำรายงานการเงินประจำปีนี้ให้หน่อย
rpt_04	single	0	3	2	0	เดือนที่แล้วรายรับหักรายจ่ายแล้วเหลือเท่าไร
rpt_05	single	2	1	3	3	ขอรายงานรายจ่ายแยกตามหมวดของเดือนที่แล้ว
rpt_06	single	0	3	2	3	สรุปการเงินไตรมาสนี้ให้หน่อย
crs_01	cross	1	0	3	1	จากรายจ่ายเดือนที่แล้ว ฉันจะเก็บเงินไปเที่ยวญี่ปุ่นได้ครบตามเป้าไหม
crs_02	cross	0	0	2	1	เดือนที่แล้วใช้จ่ายไปเท่าไร แล้วมีอะไรที่เอาไปลดหย่อนภาษีได้บ้าง
crs_03	cross	1	3	3	2	พอร์ตของฉันตอนนี้เป็นยังไง แล้วควรปรับพอร์ตไหม
crs_04	cross	3	3	3	3	บันทึกค่าข้าวเย็น 120 บาท แล้วบอกหน่อยว่าเดือนนี้ใช้ค่าอาหารไปเท่าไรแล้ว
crs_05	cross	2	0	0	0	รายได้ปีละ 720,000 บาท มีแค่ค่าลดหย่อนส่วนตัว ต้องเสียภาษีเท่าไร และควรออมเพิ่มเดือนละเท่าไรดี
crs_06	cross	2	3	3	3	ราคาหุ้น PTT ตอนนี้เท่าไร และฉันถืออยู่กี่หุ้น
crs_07	cross	3	0	0	0	สุขภาพการเงินของฉันเป็นยังไง แล้วกองทุนฉุกเฉินควรเก็บเพิ่มอีกเท่าไร
crs_08	cross	3	3	1	1	สรุปรายงานเดือนที่แล้ว แล้วแนะนำวิธีลดรายจ่ายให้หน่อย
crs_09	cross	0	0	0	0	รายได้ปีละ 600,000 บาท ถ้าซื้อ RMF 100,000 บาท ภาษีจะเหลือเท่าไร แล้ว RMF ที่ฉันถืออยู่ตอนนี้มีมูลค่าเท่าไร
crs_10	cross	2	3	3	3	ได้โบนัส 40,000 บาท บันทึกเป็นรายรับ แล้วเอาไปเพิ่มในกองทุนสำรองฉุกเฉินทั้งหมด
crs_11	cross	3	3	2	3	หุ้นที่ฉันถืออยู่มีข่าวอะไรบ้าง ควรกังวลไหม
crs_12	cross	1	0	0	0	ค่ารักษาพยาบาลเอาไปลดหย่อนภาษีได้ไหม แล้วเดือนที่แล้วฉันจ่ายค่าสุขภาพไปเท่าไร
vag_01	vague	3	3	3	3	เงิน
vag_02	vague	3	3	3	3	การเงิน
vag_03	vague	3	3	3	3	ช่วยหน่อย
vag_04	vague	3	3	3	3	ทำยังไงดี
vag_05	vague	3	3	3	3	เรื่องเงิน ๆ ทอง ๆ
vag_06	vague	3	3	3	3	จัดการให้หน่อย
vag_07	vague	3	3	3	3	อยากให้ช่วยเรื่องเงิน
vag_08	vague	3	3	3	3	แล้วแต่เลย

B Router: Every Wrong Call

Table 21: Every wrong routing call of the production setup (gemini-3.5-flash, minimal thinking).

Run	Rd	ID	Expected	Got	Question
Study B	1	rpt_11	report	expense	สรุปการเงินสัปดาห์นี้ให้หน่อย
Study B	1	s35_route_expense_005	expense	report	วิเคราะห์รายจ่ายตามหมวดหมู่
Study B	1	vag_07	clarify	report	การเงินฉัน
Study B	1	rec_13	recommendation	general_chat	ทำยังไงให้มีเงินเหลือเก็บมากขึ้นทุกเดือน
Study B	1	pln_08	planning	general_chat	เงินเดือน 30,000 ควรแบ่งออมก่อนใช้ยังไง
Study B	1	s35_route_ambig_002	expense	planning	ค่าใช้จ่ายเยอะเกินงบ ต้องวางแผนใหม่
Study B	1	s35_route_ambig_003	asset_monitoring	tax	หุ้นที่ซื้อขาดทุน ควรขายเพื่อลดหย่อนภาษีมั้ย

Run	Rd	ID	Expected	Got	Question
Study B	1	rec_15	recommendation	general_chat	should I pay off my debt or invest first
Study B	1	gen_07	general_chat	clarify	สวัสดีครับ
Study B	1	rec_07	recommendation	general_chat	อยากรวยเร็ว ควรกู้เงินมาลงทุนดีไหม
Study B	1	pln_13	planning	recommendation	ทำยังไงถึงจะเก็บเงินได้ครบตามเป้าเร็วขึ้น
Study B	2	gen_07	general_chat	clarify	สวัสดีครับ
Study B	2	s35_route_ambig_003	asset_monitoring	tax	หุ้นที่ซื้อขาดทุน ควรขายเพื่อลดหย่อนภาษีมั้ย
Study B	2	s35_route_ambig_002	expense	planning	ค่าใช้จ่ายเยอะเกินงบ ต้องวางแผนใหม่
Study B	2	his_10	planning	expense	เติมอันแรกอีก 2,000
Study B	2	pln_13	planning	recommendation	ทำยังไงถึงจะเก็บเงินได้ครบตามเป้าเร็วขึ้น
Study B	2	rec_15	recommendation	general_chat	should I pay off my debt or invest first
Study B	2	rec_07	recommendation	general_chat	อยากรวยเร็ว ควรกู้เงินมาลงทุนดีไหม
Multi-intent	1	s35_route_ambig_003	asset_monitoring	tax	หุ้นที่ซื้อขาดทุน ควรขายเพื่อลดหย่อนภาษีมั้ย
Multi-intent	1	rec_07	recommendation	general_chat	อยากรวยเร็ว ควรกู้เงินมาลงทุนดีไหม
Multi-intent	1	s35_route_invest_005	asset_monitoring	report	สัดส่วนพอร์ตเป็นยังไงบ้าง
Multi-intent	1	rec_15	recommendation	general_chat	should I pay off my debt or invest first
Multi-intent	1	s35_route_ambig_005	recommendation	report, recommendation	ช่วยดูภาพรวมการเงินแล้วแนะนำด้วย
Multi-intent	1	rpt_02	report	expense	สรุปรายรับรายจ่ายทั้งปี 2569
Multi-intent	1	s35_route_ambig_002	expense	planning	ค่าใช้จ่ายเยอะเกินงบ ต้องวางแผนใหม่
Multi-intent	1	his_10	planning	expense	เติมอันแรกอีก 2,000
Multi-intent	1	ast_11	asset_monitoring	recommendation	หากองทุน RMF ที่ลงทุนหุ้นต่างประเทศให้หน่อย
Multi-intent	1	his_07	recommendation	general_chat	ข้อแรกต้องทำยังไง

C Multi-Topic Routing Questions

Table 22: Multi-topic routing questions and router output (gemini-3.5-flash, minimal thinking).

ID	Kind	Expected	Predicted	Match	Message
m2_01	multi	expense, asset_monitoring	expense, asset_monitoring	yes	วันนี้กินข้าวไป 150 บาท แล้วหุ้น CPN ราคาเท่าไรตอนนี้
m2_02	multi	tax, planning	tax, planning	yes	ปีนี้มีรายได้ 900,000 ต้องเสียภาษีเท่าไร แล้วอยากเกษียณตอนอายุ 55 ต้องเตรียมเงินเท่าไร
m2_03	multi	expense, planning	expense, planning	yes	ช่วยสรุปรายจ่ายเดือนนี้หน่อย แล้วตั้งเป้าเก็บเงินเที่ยวญี่ปุ่น 80,000 ใน 1 ปีด้วย
m2_04	multi	report, recommendation	report, recommendation	yes	ขอรายงานการเงินปีนี้ แล้วแนะนำหน่อยว่าควรปรับอะไร
m2_05	multi	expense, tax	expense, tax	yes	ได้เงินเดือนเข้า 35,000 บันทึกให้ที แล้วลดหย่อนภาษีด้วยประกันสุขภาพได้สูงสุดเท่าไร
m2_06	multi	asset_monitoring, planning	asset_monitoring, planning	yes	ซื้อกองทุน K-USA-A(A) ไป 10,000 บาท แล้วเป้าหมายเงินฉุกเฉินตอนนี้ถึงไหนแล้ว
m2_07	multi	recommendation, asset_monitoring	recommendation, asset_monitoring	yes	สุขภาพการเงินฉันเป็นยังไง แล้วข่าวทองคำวันนี้มีอะไรบ้าง
m2_08	multi	expense, report	expense, report	yes	จ่ายค่าเช่าห้อง 6,500 บาท แล้วสรุปภาพรวมการเงินเดือนนี้ให้หน่อย
m2_09	multi	tax, asset_monitoring	tax, asset_monitoring	yes	ภาษีปีนี้ต้องจ่ายเท่าไรจากข้อมูลที่บันทึกไว้ แล้วพอร์ตตอนนี้กำไรหรือขาดทุน
m2_10	multi	general_chat, expense	general_chat, expense	yes	ดอกเบี้ย ทบ ต้น คือ อะไร แล้ว ช่วย บันทึก ค่า ไฟ 1,100 บาทด้วย
m2_11	multi	asset_monitoring, tax	asset_monitoring, tax	yes	เพิ่ม PTT เข้ารายการติดตาม แล้วคำนวณภาษีจากเงินเดือน 45,000 ให้หน่อย
m2_12	multi	expense, planning	expense, planning	yes	เมื่อวานจ่ายค่าหมอ 2,300 บาท แล้วอยากซื้อบ้านราคา 3 ล้านในอีก 5 ปีต้องเก็บดาวน์เดือนละเท่าไร
m3_01	multi	expense, asset_monitoring, report	expense, asset_monitoring, report	yes	บันทึกรายรับฟรีแลนซ์ 12,000 บาท ดูราคา SCC ล่าสุด แล้วขอรายงานสรุปไตรมาสนี้

ID	Kind	Expected	Predicted	Match	Message
m3_02	multi	tax, recommendation, planning	tax, recommendation, planning	yes	ต้อง เสีย ภาษี เท่าไร ถ้า รายได้ ปี ละ 1.2 ล้าน ควร ลงทุน อะไร เพิ่ม ดี และ เป้าหมาย เกษียณ ยัง ทัน ไหม
m3_03	multi	expense, asset_monitoring, general_chat	expense, asset_monitoring, general_chat	yes	จ่าย ค่าประกันรถ 18,000 แล้ว บันทึก ด้วย พอร์ต กองทุน เป็น ยังไง บ้าง แล้ว ดอกเบี้ย เงิน ฝาก ประจำ ต่างจาก ออมทรัพย์ ยังไง
m3_04	multi	expense, recommendation, tax	expense, recommendation, tax	yes	สรุป รายจ่าย หมวด อาหาร เดือน นี้ วิเคราะห์ สุขภาพ การเงิน ให้ หน่อย แล้ว ลดหย่อน ThaiESG ได้ เท่าไร
m3_05	multi	planning, asset_monitoring, report	planning, asset_monitoring, report	yes	ตั้ง เป้า เก็บ เงิน ซื้อ รถ 500,000 ใน 4 ปี เพิ่ม หุ้น AOT เข้า รายการ ติดตาม และ สรุป การเงิน ทั้งปี ให้ หน่อย
m3_06	multi	expense, tax, recommendation	expense, tax, recommendation	yes	ได้ โบนัส 60,000 บันทึก เป็น รายรับ คำนวณ ภาษี ใหม่ รวม โบนัส แล้ว แนะนำ ว่า ควร เอา ไป ทำ อะไร ดี
m4_01	multi	expense, asset_monitoring, tax, planning	expense, asset_monitoring, tax, planning	yes	ค่า แท็กซี่ 240 บาท บันทึก ให้ ด้วย ราคา บิตคอยน์ ตอน นี้ เท่าไร ภาษี ปี นี้ ประมาณ เท่าไร แล้ว ตั้ง เป้า เงิน ฉุกเฉิน 100,000 บาท ให้ หน่อย
m4_02	multi	report, recommendation, tax, asset_monitoring	report, recommendation, tax, asset_monitoring	yes	ขอ รายงาน เดือน นี้ วิเคราะห์ ว่า การเงิน ฉัน เป็น ยังไง ลดหย่อน ประกันชีวิต ได้ เท่าไร และ หุ้น ใน พอร์ต ตัว ไหน ขาดทุน
m4_03	multi	expense, tax, planning, recommendation	expense, tax, planning, recommendation	yes	เงิน เดือน 70,000 บันทึก ด้วย ต้อง เสีย ภาษี ปี ละ เท่าไร อยาก เก็บ เงิน แต่งงาน 400,000 ใน 3 ปี และ ควร ลงทุน แบบ ไหน ดี
m5_01	multi	expense, asset_monitoring, tax, planning, report	expense, asset_monitoring, tax, planning, report	yes	จ่าย ค่าโทรศัพท์ 599 บาท ดู ราคา GULF ภาษี ปี นี้ เท่าไร เป้าหมาย ดาวน์ บ้าน ถึง ไหน แล้ว และ ขอ รายงาน สรุป ปี นี้
s_01	single	tax	tax	yes	ซื้อ ประกันชีวิต 50,000 จะ ลดภาษี ได้ เท่าไร
s_02	single	planning	planning	yes	ช่วย วางแผน ออม เงิน เกษียณ โดย ดู จาก ราย จ่าย เดือน นี้ ของ ฉัน
s_03	single	tax	tax	yes	ขาย หุ้น SCB ได้ กำไร 20,000 ต้อง เสีย ภาษี ไหม
s_04	single	expense	expense	yes	เทียบ รายจ่าย เดือน นี้ กับ เดือน ที่แล้ว ให้ หน่อย
s_05	single	report	report	yes	สรุป รายรับ ราย จ่าย และ พอร์ต ลงทุน ทั้งหมด เป็น รายงาน เดียว
s_06	single	expense	expense	yes	บันทึก ค่าอาหาร 120 กับ ค่าเดินทาง 60 บาท
s_07	single	tax	tax	yes	สวัสดี ครับ อยาก รู้ ว่า ภาษี ปี นี้ ต้อง จ่าย เท่าไร
s_08	single	asset_monitoring	asset_monitoring	yes	ดู ราคา PTT กับ AOT ให้ หน่อย

D Datasets

The architecture tasks are listed with their results in Appendix A, and the tax cases in Table 16.

Table 23: Routing dataset (150 new + 35 September questions).

ID	Expected	Source	Question
tax_01	tax	new	เงินเดือนเดือนละ 42,000 ปีนี้ต้องจ่ายภาษีประมาณเท่าไหร่
tax_02	tax	new	ฟรีแลนซ์รายได้ปีละ 800,000 หักค่าใช้จ่ายได้กี่เปอร์เซ็นต์
tax_03	tax	new	SSF ยังลดหย่อนได้อยู่ไหมปีนี้
tax_04	tax	new	ThaiESG ลดหย่อนได้สูงสุดเท่าไร
tax_05	tax	new	เงินสมทบประกันสังคมหักลดหย่อนได้เท่าไหร่
tax_06	tax	new	ลดหย่อนเลี้ยงดูพ่อแม่ได้คนละเท่าไร
tax_07	tax	new	มีลูก 2 คน ลดหย่อนบุตรได้เท่าไหร่
tax_08	tax	new	ดอกเบี้ยผ่อนบ้านเอามาลดหย่อนได้ไหม
tax_09	tax	new	ยื่นภาษีออนไลน์ได้ถึงวันไหน
tax_10	tax	new	ถ้าซื้อประกันชีวิตเพิ่ม 50,000 จะประหยัดภาษีได้เท่าไร
tax_11	tax	new	tax bracket ของคนรายได้ 1.2 ล้านต่อปีอยู่ที่กี่เปอร์เซ็นต์
tax_12	tax	new	บริจาคเงินให้โรงพยาบาลลดหย่อนได้กี่เท่า
tax_13	tax	new	how much income tax do I pay if I earn 600k baht a year
tax_14	tax	new	โบนัสต้องเสียภาษีด้วยเหรอ
tax_15	tax	new	โดนหัก ณ ที่จ่ายไปแล้ว 20,000 จะได้เงินภาษีคืนไหม
tax_16	tax	new	เงินปันผลหุ้นไทยโดนหักภาษีกี่เปอร์เซ็นต์

ID	Expected	Source	Question
tax_17	tax	new	อยากลดภาษีให้ได้มากที่สุด ต้องซื้ออะไรบ้าง
exp_01	expense	new	กินข้าวมันไก่ 50 บาท
exp_02	expense	new	เติมน้ำมัน 1,200
exp_03	expense	new	วันนี้เงินเดือนเข้า 35,000 บาท
exp_04	expense	new	เมื่อวานจ่ายค่าไฟไป 1,850 บาท
exp_05	expense	new	ลืมจด เมื่อวานนั่งแท็กซี่ 140
exp_06	expense	new	อาทิตย์นี้ใช้เงินช้อปปิ้งไปเท่าไรแล้ว
exp_07	expense	new	ค่าเดินทางเดือนที่แล้วรวมเท่าไหร่
exp_08	expense	new	ได้ค่าจ้างงานฟรีแลนซ์มา 8,000
exp_09	expense	new	ยืมเงินแม่มา 3,000
exp_10	expense	new	คืนเงินที่ยืมพี่ไป 1,500 แล้ว
exp_11	expense	new	ตอนนี้ติดหนี้ใครอยู่บ้าง เหลือเท่าไหร่
exp_12	expense	new	มีเงินเก็บในบัญชีอยู่ 80,000
exp_13	expense	new	จ่ายเบี้ยประกันสุขภาพไป 18,000 บาท
exp_14	expense	new	netflix 419 บาท ตัดบัตรไปแล้ว
exp_15	expense	new	ลบรายการค่ากาแฟเมื่อเช้าออกให้หน่อย
exp_16	expense	new	เดือนนี้รายจ่ายหมวดไหนเยอะสุด
exp_17	expense	new	ผ่อนรถงวดนี้ 9,800 จ่ายแล้ว
ast_01	asset_monitoring	new	SCB ตอนนี้ราคาเท่าไหร่
ast_02	asset_monitoring	new	ราคาทองวันนี้เท่าไร
ast_03	asset_monitoring	new	ขาย KBANK ไป 300 หุ้นที่ 152 บาท
ast_04	asset_monitoring	new	ซื้อกองทุน K-USA-A(A) 10,000 บาท
ast_05	asset_monitoring	new	bitcoin ตอนนี้เท่าไหร่แล้ว
ast_06	asset_monitoring	new	มีข่าวอะไรเกี่ยวกับ CPALL บ้าง
ast_07	asset_monitoring	new	พอร์ตฉันตอนนี้ขาดทุนอยู่ไหม
ast_08	asset_monitoring	new	หุ้นตัวไหนในพอร์ตจ่ายปันผลดีสุด
ast_09	asset_monitoring	new	ปตท.ปิดวันนี้เท่าไร
ast_10	asset_monitoring	new	เพิ่ม DELTA เข้า watchlist ให้หน่อย
ast_11	asset_monitoring	new	หากองทุน RMF ที่ลงทุนหุ้นต่างประเทศให้หน่อย
ast_12	asset_monitoring	new	NVDA ร่วงเพราะอะไร
ast_13	asset_monitoring	new	ดัชนี SET50 ย้อนหลัง 1 เดือนเป็นยังไง
ast_14	asset_monitoring	new	แก้จำนวนหุ้น AOT ในพอร์ตเป็น 500 หุ้น
ast_15	asset_monitoring	new	กองทุนที่ถืออยู่ NAV ล่าสุดเท่าไหร่
ast_16	asset_monitoring	new	ซื้อทองคำแท่ง 1 บาท ราคา 41,000
ast_17	asset_monitoring	new	how is my portfolio doing today
pln_01	planning	new	อยากมีเงินล้านภายใน 10 ปี ต้องเริ่มยังไง
pln_02	planning	new	ตั้งเป้าเก็บเงินแต่งงาน 300,000 ภายใน 2 ปี
pln_03	planning	new	อยากมีเงินฉุกเฉินพอใช้ 6 เดือน ต้องเก็บเท่าไหร่
pln_04	planning	new	เป้าหมายเที่ยวญี่ปุ่นไปถึงไหนแล้ว
pln_05	planning	new	เพิ่มเงินเข้าเป้าหมายรถใหม่ 5,000
pln_06	planning	new	ลบเป้าหมายซื้อ iPad ออก
pln_07	planning	new	อายุ 35 มีเงินเก็บ 5 แสน จะเกษียณตอน 60 ได้ไหม
pln_08	planning	new	เงินเดือน 30,000 ควรแบ่งออมก่อนใช้ยังไง
pln_09	planning	new	ถ้าเก็บเดือนละ 3,000 อีกกี่ปีจะได้ 200,000
pln_10	planning	new	อยากเก็บเงินดาวน์คอนโด
pln_11	planning	new	เปลี่ยนเป้าหมายเงินเกษียณเป็น 8 ล้าน
pln_12	planning	new	วางแผนเก็บเงินค่าเทอมลูกปีหน้า 120,000
pln_13	planning	new	ทำยังไงถึงจะเก็บเงินได้ครบตามเป้าเร็วขึ้น
pln_14	planning	new	i want to save 50k for a new laptop by june
pln_15	planning	new	เป้าหมายไหนใกล้ครบที่สุด
pln_16	planning	new	อยากปลดหนี้บัตรเครดิตให้หมดใน 1 ปี ต้องวางแผนยังไง
pln_17	planning	new	ปีหน้าอยากเก็บให้ได้ 20% ของรายได้
rec_01	recommendation	new	ช่วยดูหน่อยว่าการเงินฉันมีจุดอ่อนตรงไหน
rec_02	recommendation	new	คะแนนสุขภาพการเงินของฉันได้เท่าไหร่
rec_03	recommendation	new	ควรลดรายจ่ายตรงไหนดี
rec_04	recommendation	new	มีเงินก้อน 2 แสน ควรเอาไปทำอะไรดี
rec_05	recommendation	new	พอร์ตฉันเสี่ยงเกินไปไหม ควรปรับยังไง
rec_06	recommendation	new	ช่วงนี้เครียดเรื่องเงินมาก ไม่รู้จะเริ่มแก้ตรงไหน

ID	Expected	Source	Question
rec_07	recommendation	new	อยากรวยเร็ว ควรกู้เงินมาลงทุนดีไหม
rec_08	recommendation	new	ช่วยประเมินว่าฉันรับความเสี่ยงได้แค่ไหน
rec_09	recommendation	new	ฉันใช้เงินเปลืองเกินไปไหม
rec_10	recommendation	new	ตอนนี้ควรถือเงินสดหรือลงทุนดี
rec_11	recommendation	new	ขอคำแนะนำการเงินที่เจาะจงกับฉันหน่อย
rec_12	recommendation	new	เพื่อนชวนลงทุน ผลตอบแทน 20% ต่อเดือน น่าลงไหม
rec_13	recommendation	new	ทำยังไงให้มีเงินเหลือเก็บมากขึ้นทุกเดือน
rec_14	recommendation	new	ตรวจสุขภาพการเงินประจำเดือนให้หน่อย
rec_15	recommendation	new	should I pay off my debt or invest first
rec_16	recommendation	new	มีอะไรที่ฉันควรรีบทำเรื่องการเงินไหม
rec_17	recommendation	new	อยากเริ่มลงทุนแต่กลัวขาดทุน ควรเริ่มยังไง
rpt_01	report	new	ขอรายงานการเงินเดือนตุลาคม
rpt_02	report	new	สรุปรายรับรายจ่ายทั้งปี 2569
rpt_03	report	new	ทำรายงานไตรมาสที่แล้วให้หน่อย
rpt_04	report	new	เดือนนี้รายรับหักรายจ่ายแล้วเหลือเท่าไร
rpt_05	report	new	export รายงานการเงินเป็น PDF ให้หน่อย
rpt_06	report	new	ขอรายงานภาพรวมรายเดือนแบบละเอียด
rpt_07	report	new	สถานะการเงินของฉันตอนนี้เป็นยังไง
rpt_08	report	new	ขอสรุปทรัพย์สินกับหนี้สินทั้งหมด
rpt_09	report	new	อัตราการออมของฉันปีนี้กี่เปอร์เซ็นต์
rpt_10	report	new	monthly financial report please
rpt_11	report	new	สรุปการเงินสัปดาห์นี้ให้หน่อย
rpt_12	report	new	ทำรายงานสรุปการเงินไว้ส่งให้แฟนดูหน่อย
rpt_13	report	new	ขอดูรายงานการเงินปีที่แล้วทั้งหมด
rpt_14	report	new	ขอ financial statement ของเดือนนี้
rpt_15	report	new	สรุปผลการเงินครึ่งปีแรกให้หน่อย
rpt_16	report	new	ความมั่งคั่งสุทธิของฉันตอนนี้เท่าไหร่
rpt_17	report	new	ปีนี้เงินเข้าออกเป็นยังไงบ้าง สรุปให้ที
gen_01	general_chat	new	กองทุนรวมคืออะไร
gen_02	general_chat	new	ดอกเบี้ยทบต้นคืออะไร
gen_03	general_chat	new	เครดิตบูโรคืออะไร ทำไมต้องสนใจ
gen_04	general_chat	new	บัตรเครดิตกับบัตรเดบิตต่างกันยังไง
gen_05	general_chat	new	กฎ 50/30/20 คืออะไร
gen_06	general_chat	new	ประกันสะสมทรัพย์คืออะไร
gen_07	general_chat	new	สวัสดีครับ
gen_08	general_chat	new	ขอบคุณมากนะ
gen_09	general_chat	new	คุณทำอะไรได้บ้าง
gen_10	general_chat	new	ถ้าเงินเฟ้อสูง ดอกเบี้ยนโยบายจะขึ้นไหม
gen_11	general_chat	new	ทำไมควรแยกบัญชีเงินออมกับบัญชีใช้จ่าย
gen_12	general_chat	new	บำนาญชราภาพประกันสังคมคำนวณยังไง
oos_01	general_chat	new	พรุ่งนี้ฝนจะตกไหม
oos_02	general_chat	new	แนะนำหนังน่าดูหน่อย
oos_03	general_chat	new	ใครชนะบอลเมื่อคืน
oos_04	general_chat	new	ช่วยแปลว่า ฉันหิวข้าว เป็นภาษาอังกฤษ
oos_05	general_chat	new	เขียนกลอนวันแม่ให้หน่อย
oos_06	general_chat	new	ลดน้ำหนักยังไงให้ได้ผล
oos_07	general_chat	new	ต้มยำกุ้งใส่อะไรบ้าง
oos_08	general_chat	new	เขียนโค้ด python เรียงตัวเลขให้หน่อย
oos_09	general_chat	new	มีเกมมือถืออะไรสนุกบ้าง
oos_10	general_chat	new	ไปเที่ยวเชียงใหม่ช่วงไหนดี
vag_01	clarify	new	ดังค์
vag_02	clarify	new	ช่วยด้วย
vag_03	clarify	new	บันทึกให้หน่อย
vag_04	clarify	new	ดูให้หน่อย
vag_05	clarify	new	อยากถามเรื่องเงิน
vag_06	clarify	new	ปรึกษาหน่อย
vag_07	clarify	new	การเงินฉัน
vag_08	clarify	new	เท่าไหร่
vag_09	clarify	new	ทำยังไงดี
vag_10	clarify	new	เรื่องเงินอะ

ID	Expected	Source	Question
vag_11	clarify	new	ขอข้อมูลหน่อย
vag_12	clarify	new	อันนี้ได้ไหม
his_01	asset_monitoring	new	ตอนนี้กำไรหรือยัง
his_02	expense	new	ค่าน้ำอีก 15
his_03	tax	new	ถ้าซื้อ SSF 50,000 ล่ะ
his_04	planning	new	4 ปี
his_05	asset_monitoring	new	ตัวแรก NAV เท่าไหร่
his_06	report	new	แล้วเดือนตุลาคมล่ะ
his_07	recommendation	new	ข้อแรกต้องทำยังไง
his_08	expense	new	เดือนที่แล้วล่ะ
his_09	asset_monitoring	new	มีข่าวอะไรไหม
his_10	planning	new	เติมอันแรกอีก 2,000
his_11	tax	new	แล้วอันนี้ลดหย่อนได้เท่าไหร่
his_12	recommendation	new	ควรเอาไปทำอะไรดี
his_13	general_chat	new	เปลี่ยนเรื่อง เล่าเรื่องตลกให้ฟังหน่อย
his_14	tax	new	เดือนละ 45,000
s35_route_tax_001	tax	sept35	คำนวณภาษีปี 2024 เงินเดือน 50,000 บาทต่อเดือน
s35_route_tax_002	tax	sept35	ภาษีเงินได้บุคคลธรรมดาคำนวณยังไง
s35_route_tax_003	tax	sept35	ค่าลดหย่อนส่วนตัวปีนี้เท่าไหร่
s35_route_tax_004	tax	sept35	ซื้อ RMF ลดหย่อนภาษีได้เท่าไหร่
s35_route_tax_005	tax	sept35	จ่ายภาษีเท่าไหร่ถ้ารายได้เดือนละ 100,000
s35_route_expense_001	expense	sept35	จ่ายค่ากาแฟ 80 บาท
s35_route_expense_002	expense	sept35	สรุปค่าใช้จ่ายเดือนนี้
s35_route_expense_003	expense	sept35	เดือนนี้จ่ายค่าอาหารไปเท่าไหร่
s35_route_expense_004	expense	sept35	บันทึกค่าเช่าบ้าน 15,000 บาท
s35_route_expense_005	expense	sept35	วิเคราะห์รายจ่ายตามหมวดหมู่
s35_route_invest_001	asset_monitoring	sept35	ดูพอร์ตการลงทุนของฉัน
s35_route_invest_002	asset_monitoring	sept35	ราคาหุ้น PTT วันนี้เท่าไหร่
s35_route_invest_003	asset_monitoring	sept35	ซื้อหุ้น ADVANC 100 หุ้น ราคา 200 บาท
s35_route_invest_004	asset_monitoring	sept35	กำไรขาดทุนพอร์ตเป็นเท่าไหร่
s35_route_invest_005	asset_monitoring	sept35	สัดส่วนพอร์ตเป็นยังไงบ้าง
s35_route_plan_001	planning	sept35	อยากออมเงิน 100,000 บาทภายใน 1 ปี
s35_route_plan_002	planning	sept35	วางแผนเกษียณอายุ 60 ปี
s35_route_plan_003	planning	sept35	ตั้งเป้าหมายซื้อบ้าน 3 ล้านบาท
s35_route_plan_004	planning	sept35	ดูเป้าหมายทางการเงินทั้งหมด
s35_route_plan_005	planning	sept35	ต้องออมเดือนละเท่าไหร่ถึงจะได้ 1 ล้าน
s35_route_rec_001	recommendation	sept35	วิเคราะห์สุขภาพการเงินของฉัน
s35_route_rec_002	recommendation	sept35	แนะนำวิธีปรับปรุงการเงิน
s35_route_rec_003	recommendation	sept35	มีคำแนะนำอะไรบ้าง
s35_route_report_001	report	sept35	สร้างรายงานการเงิน
s35_route_report_002	report	sept35	สรุปภาพรวมการเงินทั้งหมด
s35_route_general_001	general_chat	sept35	ดอกเบี้ยเงินฝากออมทรัพย์คืออะไร
s35_route_general_002	general_chat	sept35	เงินเฟ้อคืออะไร
s35_route_unknown_001	general_chat	sept35	วันนี้อากาศเป็นยังไง
s35_route_unknown_002	general_chat	sept35	แนะนำร้านอาหารหน่อย
s35_route_unknown_003	general_chat	sept35	เล่าเรื่องตลกให้ฟัง
s35_route_ambig_001	tax	sept35	ลงทุน RMF เพื่อลดหย่อนภาษี
s35_route_ambig_002	expense	sept35	ค่าใช้จ่ายเยอะเกินงบ ต้องวางแผนใหม่
s35_route_ambig_003	asset_monitoring	sept35	หุ้นที่ซื้อขาดทุน ควรขายเพื่อลดหย่อนภาษีมั้ย
s35_route_ambig_004	report	sept35	สรุปการเงินเดือนนี้
s35_route_ambig_005	recommendation	sept35	ช่วยดูภาพรวมการเงินแล้วแนะนำด้วย

Table 24: RAG dataset (120 questions) with relevance keys.

ID	Gold file(s)	Keywords	Question
q001	Tax_Deductions_Guide.md	อุปการะบิดามารดา + 30,000	พ่อแม่อายุเกิน 60 เอามาลดหย่อนภาษีได้คนละกี่บาท
q002	Tax_Deductions_Guide.md	ประกัน สุขภาพ บิดา มารดา + 15,000	จ่ายค่าประกันสุขภาพให้พ่อแม่ หักภาษีได้สูงสุดเท่าไหร่

ID	Gold file(s)	Keywords	Question
q003	Tax_Deductions_Guide.md	10,500	ปีหน้าเงินประกันสังคมที่โดนหักทุกเดือนเอาไปลดหย่อนได้มากสุดกี่บาท
q004	Tax_Deductions_Guide.md, Tax_Personal_Income_Guide.pdf	ดอกเบี้ย + 100,000	ผ่อนบ้านอยู่ ดอกเบี้ยที่จ่ายไปหักภาษีได้เพดานเท่าไร
q005	Tax_Deductions_Guide.md	ฝากครรภ์ + 60,000	ตั้งครรภ์และคลอดลูก ค่าใช้จ่ายเอาไปลดภาษีได้ไหม เท่าไหร่
q006	Tax_Deductions_Guide.md	SSF + สิ้นสุด	ยังซื้อ SSF เพื่อลดภาษีได้อยู่หรือเปล่า
q007	Tax_Deductions_Guide.md	2 เท่า	บริจาคให้โรงเรียนหรือโรงพยาบาลหักภาษีได้กี่เท่าของที่จ่าย
q008	Tax_Deductions_Guide.md, Retirement_Planning_Guide.md	500,000	กองทุนเกษียณทุกตัวรวมกันลดหย่อนได้ไม่เกินเท่าไหร่
q009	Tax_Thai_Personal_Income.md, Tax_Filing_Guide.md	120,000	คนโสดมีรายได้เท่าไหร่ต่อปีถึงต้องยื่นภาษี
q010	Tax_Thai_Personal_Income.md	750,001 - 1,000,000 + 20%	เงินได้สุทธิช่วง 750,001 ถึงหนึ่งล้าน โดนภาษีกี่เปอร์เซ็นต์
q011	Tax_Thai_Personal_Income.md, Tax_Filing_Guide.md	1.5%	ถ้าไม่ยื่นภาษีให้ทันกำหนดจะโดนเงินเพิ่มเดือนละเท่าไร
q012	Tax_Thai_Personal_Income.md	200,000 + จำคุก	แจ้งข้อมูลภาษีเป็นเท็จโทษหนักแค่ไหน
q013	Tax_Thai_Personal_Income.md	1 มกราคม + 31 ธันวาคม	ปีภาษีของไทยนับตั้งแต่วันไหนถึงวันไหน
q014	Tax_Filing_Guide.md	ภ.ง.ด.91	มนุษย์เงินเดือนอย่างเดียวต้องใช้แบบฟอร์มภาษีตัวไหน
q015	Tax_Filing_Guide.md	8 เมษายน	ยื่นภาษีผ่านเน็ตได้ถึงประมาณวันที่เท่าไร
q016	Tax_Filing_Guide.md	3,000 + 3 งวด	ภาษีที่ต้องจ่ายเพิ่มเยอะ ขอแบ่งจ่ายเป็นงวดได้ไหม
q017	Tax_Filing_Guide.md	1-3 เดือน	ยื่นออนไลน์แล้วรอเงินคืนภาษีนานประมาณกี่เดือน
q018	Tax_Filing_Guide.md	50 ทวิ	ต้องเตรียมเอกสารอะไรจากบริษัทบ้างตอนยื่นภาษี
q019	Tax_Filing_Guide.md	200 บาท	ยื่นแบบช้ากว่ากำหนดโดนค่าปรับกี่บาท
q020	Tax_Filing_Guide.md, Tax_VAT_Withholding.md	5 ปี	เอกสารหลักฐานภาษีควรเก็บไว้นานแค่ไหน
q021	Tax_VAT_Withholding.md	3%	รับงานฟรีแลนซ์ ลูกค้าหักภาษีไว้กี่เปอร์เซ็นต์
q022	Tax_VAT_Withholding.md	ดอกเบี้ยเงินฝาก + 15%	ดอกเบี้ยเงินฝากธนาคารถูกหักภาษีเท่าไหร่
q023	Tax_VAT_Withholding.md	ค่าเช่า + 5%	ปล่อยเช่าคอนโด ผู้เช่าต้องหักภาษีไว้กี่เปอร์เซ็นต์
q024	Tax_VAT_Withholding.md, Tax_Personal_Income_Guide.pdf	1.8	ขายของรายได้ถึงเท่าไหร่ต่อปีต้องไปจด VAT
q025	Tax_VAT_Withholding.md	7%	ตอนนี้ภาษีมูลค่าเพิ่มเก็บกี่เปอร์เซ็นต์
q026	Tax_VAT_Withholding.md	วันที่ 7	บริษัทต้องนำส่งภาษีที่หักไว้ภายในวันที่เท่าไรของเดือนถัดไป
q027	Tax_VAT_Withholding.md	ยกเว้น VAT	ธุรกิจแบบไหนบ้างที่ไม่ต้องเสีย VAT
q028	Debt_Management_Guide.md, Financial_Planning_Basics.md	40%	ผ่อนหนี้รวมกันไม่ควรเกินกี่เปอร์เซ็นต์ของเงินเดือน
q029	Debt_Management_Guide.md	1.8	ดอกเบี้ยรถแบบ flat แปลงเป็นดอกเบี้ยจริงคิดยังไง
q030	Debt_Management_Guide.md, Debt_Psychology_Payoff.md	100,000 + ปี	ถ้าจ่ายแค่ขั้นต่ำหนี้บัตรแสนนึง ต้องใช้เวลากี่ปีกว่าจะหมด
q031	Debt_Management_Guide.md	ค่าจดจำนอง	รีไฟแนนซ์บ้านต้องเสียค่าอะไรบ้าง
q032	Debt_Management_Guide.md	นอกระบบ + 36%	กู้นอกระบบดอกเบี้ยสูงแค่ไหน ผิดกฎหมายไหม
q033	Debt_Management_Guide.md	สัญญาณเตือน	สัญญาณอะไรที่บอกว่าเรากำลังมีปัญหาหนี้
q034	Debt_Psychology_Payoff.md	Ostrich	ทำไมบางคนไม่กล้าเปิดดูใบแจ้งหนี้เลย
q035	Debt_Psychology_Payoff.md, Debt_Management_Guide.md	Avalanche + ดอกเบี้ยสูง	จ่ายหนี้ก้อนที่ดอกเบี้ยแพงสุดก่อนเรียกว่าวิธีอะไร
q036	Debt_Psychology_Payoff.md	Snowball + แรงจูงใจ	ไม่แน่ใจว่าจะใช้วิธีปลดหนี้แบบไหน ควรเลือกอะไร
q037	Debt_Psychology_Payoff.md	24 ชั่วโมง	อยากหยุดซื้อของตามอารมณ์ มีเทคนิคอะไรบ้าง
q038	Debt_Psychology_Payoff.md	30% + จ่ายหนี้	ระหว่างปลดหนี้ควรแบ่งเงินเดือนยังไง
q039	Expense_Budgeting_Guide.md, Debt_Psychology_Payoff.md, Financial_Planning_Basics.md	50/30/20	แบ่งเงินเดือนแบบห้าสิบสามสิบยี่สิบคืออะไร
q040	Expense_Budgeting_Guide.md	30-40 ปี + 25-35%	อายุ 35 ควรออมเงินกี่เปอร์เซ็นต์ของรายได้
q041	Expense_Budgeting_Guide.md	Variable Expenses	ค่าใช้จ่ายคงที่กับผันแปรต่างกันยังไง
q042	Expense_Budgeting_Guide.md	BTS	อยากประหยัดค่ากินค่าเดินทางในกรุงเทพ มีวิธีไหนบ้าง
q043	Expense_Emergency_Fund.md, Expense_Budgeting_Guide.md	6-12 เดือน	ทำฟรีแลนซ์ ควรมีเงินสำรองไว้กี่เดือน
q044	Expense_Emergency_Fund.md	60,000 - 120,000	ใช้จ่ายเดือนละสองหมื่น ควรมีเงินฉุกเฉินเท่าไร

ID	Gold file(s)	Keywords	Question
q045	Expense_Emergency_Fund.md	MMF	เก็บเงินฉุกเฉินไว้ในกองทุนตลาดเงินดีไหม
q046	Expense_Emergency_Fund.md	ทองคำ + ผันผวน	เอาเงินฉุกเฉินไปซื้อหุ้นหรือทองได้ไหม
q047	Expense_Emergency_Fund.md	เติมกลับ	ใช้เงินสำรองไปแล้วต้องทำอะไรต่อ
q048	Expense_Emergency_Fund.md	10% ของรายได้	เริ่มเก็บเงินฉุกเฉินควรหักจากเงินเดือนกี่เปอร์เซ็นต์
q049	Finance_Psychology_Of_Money.md	พฤติกรรม	หนังสือ Psychology of Money บอกว่าอะไรสำคัญกว่าความรู้เรื่องเงิน
q050	Finance_Psychology_Of_Money.md	Warren Buffett	ทำไม Warren Buffett ถึงรวยมากตอนแก่
q051	Finance_Psychology_Of_Money.md	ค่าเข้า	ความผันผวนของตลาดควรมองว่าเป็นค่าอะไร
q052	Finance_Psychology_Of_Money.md	Save Money	ควรมีเงินออมแม้ยังไม่มีเป้าหมายไหม
q053	Finance_Psychology_Of_Money.md	Reasonable	แผนการเงินที่ดีที่สุดในทางทฤษฎีจำเป็นต้องดีที่สุดสำหรับเราไหม
q054	Financial_Planning_Basics.md	72	อยากรู้ว่าเงินจะโตเป็นสองเท่าในกี่ปี คิดง่าย ๆ ยังไง
q055	Financial_Planning_Basics.md	Net Worth	มูลค่าสุทธิของตัวเองคำนวณยังไง
q056	Financial_Planning_Basics.md	6,100,000	ลงทุนเดือนละ 5,000 นาน 30 ปีจะได้เงินประมาณเท่าไหร่
q057	Financial_Planning_Basics.md	บำนาญ + 200,000	ประกันชีวิตแบบบำนาญหักภาษีได้สูงสุดเท่าไหร่
q058	Financial_Planning_Basics.md	50-60 ปี	อายุ 50 กว่าใกล้เกษียณ ควรปรับการเงินยังไง
q059	Financial_Planning_Basics.md	ระยะกลาง	เป้าหมายการเงินระยะกลางมีอะไรบ้าง
q060	Insurance_Life_Health.md	Term Life	ประกันชีวิตแบบไหนเบี้ยถูกที่สุดแต่ไม่มีเงินคืน
q061	Insurance_Life_Health.md	สะสมทรัพย์	ประกันแบบออมเงินด้วยคุ้มครองด้วยได้เงินคืนเท่าไหร่
q062	Insurance_Life_Health.md	OPD	ประกันสุขภาพแบบไม่ต้องนอนโรงพยาบาลเรียกว่าอะไร
q063	Insurance_Life_Health.md	Unit Linked	ประกันที่ผสมการลงทุนในกองทุนเสี่ยงไหม
q064	Insurance_Social_Security.md	875	ปี 2569 ประกันสังคมหักเงินเดือนสูงสุดเดือนละกี่บาท
q065	Insurance_Social_Security.md	432	ลาออกจากงานแล้วอยากส่งประกันสังคมต่อ ต้องจ่ายเดือนละเท่าไร
q066	Insurance_Social_Security.md	มาตรา 40	ฟรีแลนซ์สมัครประกันสังคมได้ไหม มีแบบไหนบ้าง
q067	Insurance_Social_Security.md	15,000	คลอดลูกเบิกประกันสังคมได้กี่บาท
q068	Insurance_Social_Security.md	900	ทำฟันใช้สิทธิประกันสังคมได้ปีละเท่าไหร่
q069	Insurance_Social_Security.md	50,000	ผู้ประกันตนเสียชีวิต ญาติได้ค่าทำศพเท่าไร
q070	Investment_DCA_Strategy.md	Lump Sum	ทยอยลงทุนทุกเดือนดีกว่าลงก้อนเดียวยังไง
q071	Investment_DCA_Strategy.md	ขาขึ้น	ช่วงตลาดขึ้นยาว ๆ การลงทุนรายเดือนยังคุ้มไหม
q072	Investment_DCA_Strategy.md	เงินเดือนออก	ควรตั้งซื้อกองทุนอัตโนมัติวันไหนของเดือน
q073	Investment_DCA_Strategy.md	9.70	ลงทุนสม่ำเสมอ 12 เดือนในตัวอย่าง ต้นทุนเฉลี่ยต่อหน่วยเท่าไร
q074	Investment_Digital_Assets.md	เงินตรา	บิทคอยน์ใช้จ่ายแทนเงินบาทได้ตามกฎหมายไหม
q075	Investment_Digital_Assets.md	ขาดทุน	ขาดทุนจากคริปโตเอาไปหักภาษีได้ไหม
q076	Investment_Digital_Assets.md	หลอกลวง	จะรู้ได้ยังไงว่าโครงการคริปโตเป็นแชร์ลูกโซ่
q077	Investment_Digital_Assets.md	ผู้ประกอบธุรกิจ	ซื้อขายเหรียญดิจิทัลต้องทำผ่านใคร
q078	Investment_ETF_Bonds.md	0.1-0.5%	ETF ค่าธรรมเนียมถูกกว่ากองทุนรวมแค่ไหน
q079	Investment_ETF_Bonds.md	K-US500X	อยากลงทุน S&P 500 จากไทยมีกองทุนไหนบ้าง
q080	Investment_ETF_Bonds.md	2-3%	พันธบัตรรัฐบาลให้ดอกเบี้ยประมาณเท่าไหร่
q081	Investment_ETF_Bonds.md	70-80%	อายุ 25 ควรถือหุ้นกับตราสารหนี้สัดส่วนเท่าไร
q082	Investment_ETF_Bonds.md	หุ้นกู้ + 15%	ดอกเบี้ยหุ้นกู้โดนหักภาษีกี่เปอร์เซ็นต์
q083	Investment_Earthh_Evans_Lifelong.md	6 เท่า	ก่อนเริ่มลงทุนควรมีเงินสำรองกี่เท่าของค่าใช้จ่าย
q084	Investment_Earthh_Evans_Lifelong.md	10–20%	พอร์ตมือใหม่ควรแบ่งส่วนเสี่ยงสูงไว้ประมาณเท่าไร
q085	Investment_Earthh_Evans_Lifelong.md	moat	เลือกหุ้นรายตัวควรถามตัวเองเรื่องอะไรบ้าง
q086	Investment_Earthh_Evans_Lifelong.md	30%	ถ้าหุ้นที่จะซื้อร่วง 30% พรุ่งนี้ ควรคิดยังไงก่อนซื้อ
q087	Investment_Mutual_Funds.md	KTAM	กองทุนที่ชื่อขึ้นต้นด้วย KT- เป็นของบริษัทไหน
q088	Investment_Mutual_Funds.md	Management Fee	ค่าธรรมเนียมจัดการกองทุนต่อปีประมาณเท่าไร
q089	Investment_Mutual_Funds.md	FIF	กองทุนที่ลงทุนหุ้นต่างประเทศเรียกว่าอะไร
q090	Investment_Mutual_Funds.md	NAV	NAV ของกองทุนคืออะไร
q091	Investment_Thai_Stocks.md	14:30	ตลาดหุ้นไทยเปิดซื้อขายช่วงบ่ายกี่โมง
q092	Investment_Thai_Stocks.md	T+2	ซื้อหุ้นแล้วต้องจ่ายเงินภายในกี่วัน
q093	Investment_Thai_Stocks.md	0.15%	ค่าคอมซื้อขายหุ้นประมาณกี่เปอร์เซ็นต์
q094	Investment_Thai_Stocks.md	mai	ตลาด mai ต่างจาก SET ยังไง

ID	Gold file(s)	Keywords	Question
q095	Investment_Thai_Stocks.md	Capital Gains	ขายหุ้นในตลาดได้กำไร ต้องเสียภาษีไหม
q096	Planning_Savings_Guide.md	SMART	ตั้งเป้าออมแบบ SMART หมายถึงอะไร
q097	Planning_Savings_Guide.md	800,000 + 160,000	ซื้อรถแปดแสน ควรดาวน์เท่าไหร่
q098	Planning_Savings_Guide.md	4,500	เงินเดือนสามหมื่น ผ่อนรถได้ไม่ควรเกินเดือนละเท่าไร
q099	Planning_Savings_Guide.md	360,000	ซื้อบ้านสามล้าน ต้องเตรียมเงินสดรวมประมาณเท่าไร
q100	Planning_Savings_Guide.md	ค่าโอน + 2%	ค่าโอนกรรมสิทธิ์ตอนซื้อบ้านคิดกี่เปอร์เซ็นต์
q101	Retirement_Planning_Guide.md, Financial_Planning_Basics.md	× 25|25 เท่า	ตอนเกษียณต้องมีเงินกี่เท่าของค่าใช้จ่ายต่อปี
q102	Retirement_Planning_Guide.md	400,000	มีเงินสิบล้านตอนเกษียณ ปีแรกถอนใช้ได้เท่าไหร่
q103	Retirement_Planning_Guide.md	180 เดือน	ต้องส่งประกันสังคมกี่เดือนถึงจะได้บำนาญ
q104	Retirement_Planning_Guide.md	55 ปี	RMF ต้องถือถึงอายุเท่าไรถึงขายได้โดยไม่เสียสิทธิ
q105	Retirement_Planning_Guide.md, Tax_Deductions_Guide.md	30,000	กอช. ออมได้ปีละมากสุดเท่าไร
q106	Retirement_Planning_Guide.md	กบข + 3%	ข้าราชการสะสมเงินเข้า กบข. กี่เปอร์เซ็นต์
q107	Tax_PIT90_Guide_2568.pdf	40 (1) - (8)	แบบ ภ.ง.ด.90 ใช้กับคนมีเงินได้ประเภทไหน
q108	Tax_PIT90_Guide_2568.pdf	31 พฤษภาคม	ผ่อนชำระภาษีงวดสุดท้ายของปีภาษี 2568 ต้องจ่ายภายในวันไหน
q109	Tax_PIT90_Guide_2568.pdf	คู่สมรสต่างฝ่าย + 100,000	สามีภรรยาต่างคนต่างมีรายได้ หักลดหย่อนประกันชีวิตได้คนละเท่าไร
q110	Tax_PIT90_Guide_2568.pdf	ไม่น้อยกว่า 5 ปี	ThaiESG ต้องถือหน่วยลงทุนนานกี่ปี
q111	Tax_PIT90_Guide_2568.pdf	ก่อสร้างอาคาร + 86/4	ค่าจ้างสร้างบ้านเอามาหักภาษีได้ ต้องมีหลักฐานอะไร
q112	Tax_PIT90_Guide_2568.pdf	2,000,000 + 25	เงินได้สุทธิเกินหนึ่งล้านถึงสองล้าน อัตราภาษีกี่เปอร์เซ็นต์ตามแบบ ภ.ง.ด.90
q113	Tax_Personal_Income_Guide.pdf	30 กันยายน	ร้านค้าในโครงการคนละครึ่งต้องยื่นภาษีครึ่งปีภายในวันไหน
q114	Tax_Personal_Income_Guide.pdf	0.005	วิธีคำนวณภาษีแบบ 0.5% ของเงินได้ใช้เมื่อไหร่
q115	Tax_Personal_Income_Guide.pdf, Tax_PIT90_Guide_2568.pdf	ร้อยละ 60	อาชีพแพทย์ หักค่าใช้จ่ายแบบเหมาได้กี่เปอร์เซ็นต์
q116	Finance_Behavioral_Finance_Ritter.pdf	EMH + rational	Does the efficient market hypothesis assume every investor is rational?
q117	Finance_Behavioral_Finance_Ritter.pdf	Framing	Why do restaurants call it an early-bird special instead of a peak-hour surcharge?
q118	Finance_Behavioral_Finance_Ritter.pdf	LTCM	What happened to LTCM's trade on the twin shares?
q119	Finance_Behavioral_Reasoning_Chains.pdf	19k	How many samples are in the behaviorally grounded personal finance dataset?
q120	Finance_Behavioral_Reasoning_Chains.pdf	Borda + 8B	Which small model gave the best relevance per billion parameters?